





دانشگاه شهید بهشتی
دانشکده مهندسی برق (کنترل و قدرت)

پروژه کارشناسی مهندسی برق

عنوان پروژه:

تشخیص پلاک خودرو به وسیله روشهای شبکه عصبی به همراه اپلیکیشن

استاد راهنما:

سرکار خانم دکتر فاطمه جهانگیری

نام دانشجو:

زهرا سیه چهره خلردی

فهرست

3	فصل اول
3	1-1-مقدمه
3	2-1-پیشینه و روندهای جهانی
4	3-1-کاربردها و سناریوهای استفاده
4	4-1-چالش‌های فنی در محیط‌های واقعی
5	5-1-بیان مسئله و پرسش‌های تحقیق
5	6-1-ضرورت و اهمیت انجام پروژه
6	7-1-اهداف پژوهش
7	8-1-دامنه، محدودیت‌ها و فرضیات
7	9-1-تعاریف و اختصارات
7	10-1-روش کلی انجام پروژه
8	11-1-مخاطرات، ملاحظات حقوقی و اخلاقی
8	12-1-ساختار پایان‌نامه
8	13-1-چشم‌انداز فنی و نقشه راه توسعه
8	14-1-جمع‌بندی فصل
9	2-فصل دوم
9	1-2-مقدمه
9	2-2-مفاهیم پایه‌ای پردازش تصویر
10	2-2-1-مراحل پردازش تصویر
11	2-2-2-تکنیک‌های کلاسیک پردازش تصویر
12	2-2-3-ارتباط روش‌های کلاسیک با یادگیری عمیق
12	2-3-شبکه‌های عصبی و یادگیری عمیق در بینایی ماشین
12	2-3-1-معرفی شبکه‌های عصبی کانولوشنی (CNN)
13	2-3-2-ساختار معماری‌های معروف (LeNet, AlexNet, VGG, ResNet)
13	2-3-3-کاربرد CNN در تشخیص اشیا
13	2-4-معماری‌های مدرن آشکارسازی پلاک

13.....	۱-۴-۲- معرفی YOLO نسخه‌های v3 تا v8
14.....	۲-۴-۲- SSD و Faster R-CNN
14.....	۳-۴-۲- مقایسه دقت و سرعت
14	۵-۲- OCR و شناسایی کاراکترها
14.....	۱-۵-۲- تاریخچه OCR (Tesseract)
15.....	۲-۵-۲- مدل‌های عمیق‌تر مثل CRNN
15.....	۳-۵-۲- چالش‌های OCR برای زبان فارسی/پلاک‌های ایران
15	۶-۲- کارهای مرتبط و تحقیقات پیشین
15.....	۱-۶-۲- پروژه‌ها و مقالات بین‌المللی
16.....	۳-۶-۲- تحلیل نقاط ضعف و قوت
16	۷-۲- جمع‌بندی فصل
16.....	۱-۷-۲- نکات کلیدی مبانی نظری
19.....	فصل سوم
19	۱-۳- مقدمه
19	۲-۳- مراحل کلی انجام پروژه
19.....	۱-۲-۳- جمع‌آوری و آماده‌سازی داده‌ها
19.....	۲-۲-۳- پیش‌پردازش تصاویر
20.....	۳-۲-۳- آموزش و ارزیابی مدل‌های آشکارساز (YOLOv5, YOLOv8, Faster R-CNN)
20.....	۴-۲-۳- پیاده‌سازی OCR یا CRNN یا Tesseract
20.....	۵-۲-۳- طراحی مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)
21	۳-۳- جمع‌آوری و آماده‌سازی داده‌ها
21.....	۱-۳-۳- معرفی دیتاست‌های جهانی
21.....	۲-۳-۳- جمع‌آوری تصاویر بومی (پلاک‌های ایرانی)
22.....	۳-۳-۳- فرآیند لیبل‌گذاری و یکپارچه‌سازی
22.....	۴-۳-۳- تکنیک‌های Data Augmentation
23	۴-۳- پیش‌پردازش تصاویر
23.....	۱-۴-۳- اصلاح روشنایی و کنتراست
23.....	۲-۴-۳- نرمال‌سازی ابعاد
24.....	۳-۴-۳- حذف نویز
24.....	۴-۴-۳- استفاده از Adaptive Thresholding
24	۵-۳- آموزش و ارزیابی مدل‌ها
24.....	۱-۵-۳- YOLOv5 و YOLOv8
25.....	۲-۵-۳- Faster R-CNN
25.....	۳-۵-۳- معیارهای ارزیابی
26	۶-۳- OCR و شناسایی کاراکترها
26.....	۱-۶-۳- استفاده از CRNN

26.....	۲-۶-۳ معرفی Tesseract و آموزش سفارشی روی داده‌های فارسی.
26.....	۳-۶-۳ مقایسه عملکرد CRNN و Tesseract
26	۷-۳ مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)
26.....	۱-۷-۳ ایده اصلی
26.....	۲-۷-۳ معیارهای انتخاب
27.....	۳-۷-۳ الگوریتم تصمیم‌گیری
27	۸-۳ جمع‌بندی فصل سوم
29.....	فصل چهارم
29	۱-۴ مقدمه
29	۲-۴ ابزارها و محیط توسعه
29.....	۱-۲-۴ زبان برنامه‌نویسی (Python)
30.....	۲-۲-۴ کتابخانه‌ها
30.....	۳-۲-۴ محیط‌های اجرا
31.....	۴-۲-۴ ابزارهای کمکی
31	۳-۴ پیاده‌سازی مازول پیش‌پردازش
31.....	۱-۳-۴ تبدیل تصویر به خاکستری (Grayscale Conversion)
32.....	۲-۳-۴ حذف نویز (Noise Reduction)
32.....	۳-۳-۴ اصلاح روشنایی و کنتراست
32.....	۴-۳-۴ آستانه‌گذاری تطبیقی (Adaptive Thresholding)
32.....	۵-۳-۴ نمونه کد پیش‌پردازش
33	۴-۴ پیاده‌سازی آشکارساز پلاک
33.....	۱-۴-۴ آموزش مدل YOLOv5 و YOLOv8
33.....	۲-۴-۴ استفاده از Faster R-CNN
34.....	۳-۴-۴ مقایسه نتایج خروجی سه مدل
34.....	۴-۴-۴ نمونه کد YOLOv5
34	۵-۴ پیاده‌سازی OCR
34.....	۱-۵-۴ به‌کارگیری Tesseract OCR
34.....	۲-۵-۴ پیاده‌سازی CRNN
34.....	۳-۵-۴ مقایسه خروجی OCR در شرایط مختلف
35	۶-۴ مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)
35.....	۱-۶-۴ توضیح الگوریتم تصمیم‌گیری
35.....	۲-۶-۴ معیارهای انتخاب مدل
36.....	۳-۶-۴ پیاده‌سازی Rule-based و نسخه ML-based
36.....	۴-۶-۴ نمونه کد
37	۷-۴ پیاده‌سازی اپلیکیشن (Web Application / API)
37.....	۱-۷-۴ معرفی Flask به‌عنوان چارچوب وب

37	۴-۷-۲- طراحی رابط کاربری ساده
37	۴-۷-۳- یکپارچه‌سازی آشکارساز + OCR + سوییچینگ
37	۴-۷-۴- استفاده از ngrok برای دسترسی خارجی
38	۴-۸- نمونه خروجی‌ها
38	۴-۹- جمع‌بندی فصل چهارم
40	فصل پنجم
40	۵-۱- مقدمه
40	۵-۲- مشخصات سخت‌افزاری و نرم‌افزاری آزمایش‌ها
40	۵-۲-۱- سخت‌افزار
41	۵-۲-۲- محیط نرم‌افزاری
41	۵-۳- نتایج مربوط به پیش‌پردازش تصاویر
41	۵-۳-۱- نمایش تصاویر قبل و بعد از پیش‌پردازش
42	۵-۳-۲- تحلیل اثر پیش‌پردازش بر دقت مدل‌ها
42	۵-۴- نتایج آشکارسازی پلاک
42	۵-۴-۱- مقایسه عملکرد YOLOv5 ، YOLOv8 و Faster R-CNN
43	۵-۴-۲- تحلیل معیارها و عملکرد
43	۵-۴-۳- نقاط قوت و ضعف هر مدل
43	۵-۵- نتایج OCR و شناسایی کاراکترها
43	۵-۵-۱- مقایسه دقت CRNN و Tesseract
43	۵-۵-۲- تحلیل عملکرد در شرایط نوری و زاویه‌ای مختلف
44	۵-۵-۳- مقایسه کمی (توضیحی)
44	۵-۶- نتایج مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)
44	۵-۶-۱- بهبود دقت در شرایط سخت
44	۵-۶-۲- مقایسه عملکرد با و بدون سوییچینگ (توضیحی)
45	۵-۷- رابط وب و تست عملی
45	۵-۷-۱- نمایش رابط وب
45	۵-۷-۲- تست عملی توسط کاربر
45	۵-۷-۳- استفاده از ngrok برای دسترسی خارجی
45	۵-۸- مقایسه با کارهای پیشین
45	۵-۹- جمع‌بندی فصل پنجم
46	فصل ششم
46	۶-۱- مقدمه
47	۶-۲- تحلیل نتایج پیش‌پردازش

47	۱-۲-۶- تأثیر حذف نویز
47	۲-۲-۶- تأثیر اصلاح روشنایی و کنتراست
47	۳-۲-۶- تأثیر Adaptive Thresholding
47	۴-۲-۶- تحلیل هزینه محاسباتی در مقابل بهبود دقت
48	۳-۶- تحلیل نتایج آشکارسازها (YOLOv5, YOLOv8, Faster R-CNN)
48	۱-۳-۶- نقاط قوت و ضعف هر مدل
48	۲-۳-۶- مقایسه عملی در شرایط بلادرنگ و غیربلادرنگ
48	۳-۳-۶- تحلیل مناسبترین مدل برای شرایط ایران
49	۴-۶- تحلیل نتایج OCR (Tesseract vs CRNN)
49	۱-۴-۶- چرایی عملکرد بهتر CRNN در شرایط دشوار
49	۲-۴-۶- محدودیت‌های Tesseract در پلاک‌های فارسی
49	۳-۴-۶- پیشنهاد برای ترکیب دو رویکرد
50	۵-۶- تحلیل مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)
50	۱-۵-۶- ارزیابی پایداری سیستم
50	۲-۵-۶- مقایسه هزینه محاسباتی و بهبود دقت
50	۳-۵-۶- Rule-based یا ML-based
51	۶-۶- مقایسه با کارهای پیشین
51	۱-۶-۶- جایگاه پروژه نسبت به کارهای داخلی و خارجی
51	۲-۶-۶- نوآوری‌ها و مزیت‌های رقابتی پروژه
51	۷-۶- محدودیت‌های پروژه
51	۱-۷-۶- محدودیت داده‌ها (تعداد و تنوع تصاویر)
52	۲-۷-۶- محدودیت سخت‌افزاری (وابستگی به GPU یا Colab)
52	۳-۷-۶- محدودیت در شرایط خاص پلاک‌ها
52	۸-۶- جمع‌بندی فصل ششم
54	فصل هفتم
54	۱-۷- مقدمه
54	۲-۷- نتیجه‌گیری کلی
55	۳-۷- دستاوردهای علمی و عملی پروژه
55	۱-۳-۷- دستاوردهای علمی
56	۲-۳-۷- دستاوردهای عملی
56	۴-۷- پیشنهادات برای پژوهش‌های آتی
57	۵-۷- جمع‌بندی فصل و پایان پروژه
58	6-7- تأکید بر کاربردپذیری سامانه در شرایط واقعی ایران
58	7-7- چشم‌انداز آینده و ارزش پژوهش

تشکر و قدردانی به حکم من لم یشکر المخلوق، لم یشکر الخالق

از استاد گرانقدر سرکار خانم دکتر جهانگیری که زحمت راهنمایی این پایان نامه را بر عهده داشتند، کمال تشکر را دارم. همچنین از پدر و مادر عزیز و دلسوزم بابت حمایت های همیشگی و بی دریغ شان، سپاسگزارم.

چکیده

با افزایش نیاز به سامانه‌های هوشمند حمل‌ونقل و اهمیت بالای مدیریت ترافیک و امنیت شهری، توسعه ابزارهای نوین برای تشخیص خودکار پلاک خودرو (ALPR) به ضرورتی اجتناب‌ناپذیر تبدیل شده است. سامانه‌های سنتی مبتنی بر پردازش تصویر در مواجهه با تغییرات نور، زاویه دید و کیفیت پایین تصاویر عملکرد ضعیفی دارند. در این پروژه، با هدف بهبود دقت و پایداری سامانه‌های ALPR، مدلی ترکیبی طراحی و با استفاده از روش‌های یادگیری عمیق و OCR پیشرفته پیاده‌سازی شد.

مراحل پروژه شامل جمع‌آوری داده‌های بومی از پلاک‌های ایرانی، پیش‌پردازش تصاویر (اصلاح روشنایی و کنتراست، حذف نویز و آستانه‌گذاری تطبیقی)، آموزش مدل‌های آشکارساز مدرن (YOLOv8 و Faster R-CNN) و پیاده‌سازی دو رویکرد OCR Tesseract و CRNN است. نوآوری اصلی این پژوهش طراحی ماژول Switching Adaptive Model است که بسته به کیفیت ورودی (نور، وضوح، زاویه) بهترین مدل آشکارساز و OCR را انتخاب می‌کند.

نتایج آزمایش‌ها نشان می‌دهند که ترکیب مدل‌های مختلف و استفاده از سوییچینگ تطبیقی، دقت شناسایی پلاک را به‌طور چشمگیری افزایش داده و عملکرد سامانه را در شرایط نوری و محیطی سخت پایدار کرده است. همچنین، طراحی یک اپلیکیشن تحت وب مبتنی بر Flask امکان بارگذاری تصویر/ویدئو و دریافت خروجی نهایی توسط کاربر را فراهم آورده است. این پژوهش نشان می‌دهد که سامانه پیشنهادی علاوه بر دقت بالا، قابلیت اجرای بلادرنگ و استقرار بر روی سخت‌افزارهای لبه (Edge Devices) را نیز داراست.

این پروژه با ارائه رویکردی ترکیبی و بومی، گامی مؤثر در جهت توسعه سامانه‌های هوشمند ترافیکی و امنیتی در کشور محسوب می‌شود و می‌تواند مبنایی برای تحقیقات آینده و پروژه‌های صنعتی قرار گیرد.

فصل اول

1-1- مقدمه

با گسترش روزافزون فناوری‌های هوش مصنوعی و یادگیری عمیق، بسیاری از فرایندهای سنتی مهندسی و مدیریتی به سمت اتوماسیون و هوشمندسازی حرکت کرده‌اند. یکی از حوزه‌هایی که بیشترین بهره را از این تحول برده است، حوزه سامانه‌های حمل‌ونقل هوشمند و مدیریت ترافیک شهری است. در این میان، سامانه‌های تشخیص خودکار پلاک خودرو به‌عنوان هسته اصلی بسیاری از کاربردهای نظارتی و کنترلی، نقشی تعیین‌کننده دارند.

پلاک خودرو یک شناسه یکتا برای هر وسیله نقلیه محسوب می‌شود و استخراج دقیق آن از تصاویر دوربین‌ها می‌تواند طیف گسترده‌ای از خدمات را ممکن سازد؛ از کنترل تردد در معابر محدود و اخذ عوارض بزرگراهی گرفته تا مدیریت پارکینگ‌های عمومی و خصوصی، پایش جرایم رانندگی، امنیت شهری و مرزی، و حتی تحلیل‌های کلان‌داده برای برنامه‌ریزی شهری.

با این حال، تشخیص پلاک در شرایط واقعی با دشواری‌های متعددی همراه است: تغییرات شدید روشنایی بین روز و شب، وجود سایه‌ها و انعکاس‌ها، تنوع زاویه دید دوربین نسبت به پلاک، لرزش و محوشدگی ناشی از حرکت آلودگی و پوشیدگی پلاک، تفاوت در فونت و استانداردهای نگارشی، و محدودیت‌های محاسباتی در کاربست برخی روش‌های کلاسیک پردازش تصویر (مانند آستانه‌گذاری، فیلترگذاری و تحلیل لبه) در چنین شرایطی شکننده‌اند و عملکردشان افت محسوسی پیدا می‌کند.

منجر به جهشی چشمگیر در کاربردهای (CNN) ظهور شبکه‌های عصبی عمیق، به‌ویژه شبکه‌های کانولوشنی به‌همراه Faster R-CNN و YOLO بینایی ماشین شده است. مدل‌های آشکارسازی اشیاء مانند خانواده دقیق و پایدار را ALPR امکان پیاده‌سازی سامانه‌های CRNN معماری‌های تخصصی تشخیص کاراکتر مانند در شرایط دشوار even فراهم می‌سازند. باوجود این، چالش اصلی همچنان پایداری عملکرد در شرایط متنوع و تضمین سرعت کافی برای اجرای برخی بر روی سخت‌افزارهای لبه است.

1-2- پیشینه و روندهای جهانی

تاریخچه سامانه‌های تشخیص پلاک به دهه‌های گذشته بازمی‌گردد؛ زمانی که الگوریتم‌های مبتنی بر قواعد دست‌ساخت یا ویژگی‌های لبنی (HOG) و ویژگی‌های کم‌عمق مانند هیستوگرام گرادینان‌ها (Rule-Based) غالب بودند (LBP). این روش‌ها برای محیط‌های کنترل‌شده قابل قبول بودند، اما در صحنه‌های واقعی و پرنویز ثبات لازم را نداشتند.

Faster R-CNN و R-CNN در دهه اخیر با گسترش یادگیری عمیق، ابتدا معماری‌های دو مرحله‌ای مانند با بهینه‌سازی‌های متعدد YOLO و SSD دقت بسیار بالایی را نشان دادند. سپس نسل مدل‌های تک‌مرحله‌ای نظیر موازنه‌ی بهتری میان دقت و سرعت برقرار کردند. در (YOLOv3، YOLOv5، YOLOv7 و YOLOv8) تصاویر متنی کم‌کیفیت یا منحرف‌شده به‌کار OCR برای CRNN موازات آن، معماری‌های توالی‌محور مانند گرفته شد و بهبودهای چشمگیری را در استخراج کاراکتر رقم زد.

حرکت از انتخاب یک مدل واحد برای همه شرایط «به سمت ALPR، امروزه روند غالب در پژوهش‌های ترکیب چندین مدل و انتخاب تطبیقی بر مبنای شرایط تصویر است. این راهبرد که در این پروژه از آن با عنوان «یاد می‌شود، با سنجش شاخص‌های کیفیت تصویر روشنایی، نسبت سیگنال به Adaptive Model Switching را (Pipeline) نویز، وضوح، زاویه دید یا با استفاده از یک دسته‌بند سبک پیش‌پردازشی، مناسب‌ترین لوله‌کار برای هر ورودی انتخاب می‌کند.

1-3- کاربردها و سناریوهای استفاده

ستون فقرات بسیاری از خدمات و سامانه‌های شهری هوشمند هستند. موارد زیر نمونه‌هایی ALPR سامانه‌های کلیدی از سناریوهای کاربری محسوب می‌شوند:

- مدیریت و کنترل تردد در محدوده‌های طرح ترافیک و زوج‌وفرد؛
 - اخذ خودکار عوارض جاده‌ای و بزرگراهی بدون توقف؛
 - مدیریت پارکینگ‌های عمومی و خصوصی (ورود/خروج، محاسبه هزینه، رزرو جای پارک)؛
 - پایش و ثبت تخلفات رانندگی (سرعت غیرمجاز، عبور از چراغ قرمز، توقف غیرمجاز)؛
 - امنیت شهری و مرزی (جست‌وجوی خودروهای سرقتی یا مشکوک)؛
 - پشتیبانی از تحلیل‌های کلان‌داده در برنامه‌ریزی شهری و بهینه‌سازی زیرساخت‌ها
- در همه این سناریوها، دو معیار محوری وجود دارد: دقت و زمان پاسخ. هرگونه کاهش در دقت می‌تواند به خطاهای حقوقی یا مالی بینجامد، و هرگونه تأخیر در پردازش، ارزش عملیاتی سامانه را کاهش می‌دهد. از این‌رو طراحی معماری‌ای که به‌صورت پایدار هر دو معیار را تأمین کند، ضروری است.

1-4- چالش‌های فنی در محیط‌های واقعی

- تغییرات شدید روشنایی (روز/شب، تونل‌ها، نورهای نقطه‌ای، چراغ‌های خودرو) و ایجاد اشباع یا سایه‌های عمیق؛
- زاویه دید نامتقارن و پرسپکتیو شدید که موجب تغییر شکل ناحیه پلاک و کاهش وضوح کاراکترها می‌شود؛
- حرکت نسبی زیاد در سرعت‌های بالا یا لرزش دوربین
- پوشیدگی و آلودگی پلاک، شکستگی یا خمیدگی، و تنوع فونت و چیدمان؛

- نويز حسگر و فشرده‌سازی در سامانه‌های نظارتی ارزان‌قیمت؛
 - محدودیت منابع محاسباتی در تجهیزات لبه و نیاز به پاسخ کمتر از چند ده میلی‌ثانیه
- هر یک از چالش‌های فوق نیازمند سیاست‌های فنی مکمل است: طراحی پیش‌پردازش‌های مقاوم به نور، استفاده از آشکارسازهای چندمقیاسی، بهره‌گیری از افزایش‌داده هدفمند، و در نهایت، انتخاب تطبیقی مدل برای شرایط خاص. این همان انگیزه اصلی تعریف ماژول سوییچینگ هوشمند در این پروژه است.

1-5- بیان مسئله و پرسش‌های تحقیق

- مسئله محوری این پژوهش، طراحی یک سامانه دقیق و سریع با قابلیت پایداری در شرایط واقعی متنوع است. برای صورت‌بندی روشن‌تر، پرسش‌های زیر مطرح می‌شوند:
- توانمند، موازنه بهینه دقت/سرعت را در OCR چگونه می‌توان با ترکیب چند مدل آشکارساز و یک محیط‌های واقعی برقرار کرد؟
 - با ویژگی‌های سکانسی می‌توانند برای سوییچ تطبیقی بین مدل‌ها (IQM) چه شاخص‌هایی از کیفیت تصویر به‌کار روند؟
 - حداقل الزامات سخت‌افزاری برای دستیابی به برخط‌بودن در دوربین‌های نظارتی شهری چیست؟
 - تا چه حد می‌توان با افزایش‌داده هدفمند، شکاف دامنه‌ای بین دیتاست‌های جهانی و داده‌های بومی را کاهش داد؟

1-6- ضرورت و اهمیت انجام پروژه

اهمیت این پروژه را می‌توان از دو منظر اصلی، یعنی عملیاتی و علمی، مورد تحلیل قرار داد:

(الف) منظر عملیاتی

در سال‌های اخیر، با افزایش تعداد خودروها و پیچیده‌تر شدن شبکه‌های حمل‌ونقل شهری، نیاز به سامانه‌های هوشمند مدیریت ترافیک و نظارت بیش از پیش احساس می‌شود. روش‌های دستی یا نیمه‌خودکار در حوزه کنترل عبور و مرور، دیگر پاسخگوی حجم بالای تردد وسایل نقلیه در کلان‌شهرها نیستند. از سوی دیگر، شرایط خاص کشور ایران از جمله تنوع پلاک‌ها (پلاک‌های ملی، مناطق آزاد، تاکسی‌ها، خودروهای نظامی و ...) و همچنین شرایط محیطی متغیر (آلودگی هوا، تغییرات شدید نور روز و شب، شرایط آب‌وهوایی گوناگون) ضرورت توسعه سامانه‌ای بومی و هوشمند را دوچندان می‌کند.

راهکارهای ALPR بومی‌سازی‌شده با شناخت دقیق ویژگی‌های ظاهری پلاک‌های فارسی و درک شرایط محیطی کشور، می‌توانند پاسخگوی نیازهای فوری ذینفعان کلیدی باشند. این ذینفعان شامل شهرداری‌ها برای مدیریت طرح‌های ترافیکی، پلیس راهور برای پایش تخلفات رانندگی و امنیت جاده‌ای، شرکت‌های پارکینگ و حمل‌ونقل هوشمند برای مدیریت ورود و خروج خودروها و همچنین مراکز امنیتی و مرزبانی هستند.

(ب) منظر علمی

از منظر علمی، این پروژه در پی ترکیب دو حوزه مهم هوش مصنوعی است: مدل‌های مدرن آشکارسازی اشیا و سامانه‌های تشخیص نویسه نوری. یکی از نوآوری‌های اصلی این پروژه، استفاده از راهبرد Adaptive Switching Model است. در این رویکرد، سیستم قادر است بسته به شرایط ورودی (مانند روشنایی، زاویه دید یا وضوح تصویر) به‌طور هوشمند تصمیم بگیرد که کدام مدل آشکارساز (YOLOv5، YOLOv8 یا Faster-RCNN) بهترین عملکرد را ارائه می‌دهد.

این مکانیزم تطبیقی نه تنها دقت سامانه را افزایش می‌دهد، بلکه کارایی آن را در شرایط متنوع و دشوار نیز تضمین می‌کند. در نتیجه، این پروژه می‌تواند به‌عنوان یک الگوی مرجع علمی برای توسعه سامانه‌های ALPR مقاوم در شرایط واقعی مطرح شود و مسیر پژوهش‌های آتی را نیز هموار نماید.

1-7- اهداف پژوهش

اهداف این پژوهش در دو سطح کلی و ویژه تعریف می‌شوند:

الف) اهداف کلی

طراحی و پیاده‌سازی یک سامانه ALPR بومی با قابلیت شناسایی دقیق پلاک خودروهای ایرانی.

ایجاد مکانیزمی برای پایداری عملکرد سامانه در شرایط نوری، زاویه‌ای و محیطی متنوع.

دستیابی به اجرای بلادرنگ (Real-Time) با دقت بالا، به‌ویژه در بسترهای عملیاتی شهری.

ب) اهداف ویژه

آشکارسازی ناحیه پلاک: توسعه و آموزش مدل‌های یادگیری عمیق (YOLOv5، YOLOv8، Faster-RCNN) برای شناسایی ناحیه پلاک خودروها.

تشخیص کاراکترها (OCR): استفاده از مدل‌های مبتنی بر شبکه‌های بازگشتی کانولوشنی (CRNN) یا ابزارهای قدرتمندی مانند Tesseract برای استخراج دقیق حروف و اعداد پلاک.

پیاده‌سازی مکانیزم Adaptive Model Switching: طراحی سیستمی که بسته به کیفیت ورودی، بهترین مدل آشکارساز را انتخاب کند.

یکپارچه‌سازی داده‌ها: جمع‌آوری و آماده‌سازی یک مجموعه داده ترکیبی شامل تصاویر بومی (پلاک‌های ایرانی) و دیتاست‌های جهانی؛ همراه با انجام Data Augmentation برای پوشش شرایط متنوع.

بهینه‌سازی برای Edge Devices: اطمینان از امکان اجرای سامانه بر روی سخت‌افزارهای نیمه‌سبک مانند Jetson Nano یا GPU های کوچک.

ارزیابی جامع: سنجش سامانه با معیارهای استاندارد از جمله دقت، یادآوری، F1-Score، صحت کاراکتر و نرخ فریم در ثانیه..

تحقق این اهداف موجب می‌شود سامانه نهایی علاوه بر جنبه پژوهشی، قابلیت به‌کارگیری عملی در پروژه‌های واقعی کشور را نیز داشته باشد.

8-1- دامنه، محدودیت‌ها و فرضیات

دامنه پژوهش بر سامانه‌های شناسایی پلاک خودروهای سواری و سبک متمرکز است و موارد زیر در نظر گرفته می‌شود:

- تمرکز بر پلاک‌های رایج ملی؛
- استفاده از ویدئوها و تصاویر از دوربین‌های ثابت یا نیمه‌ثابت شهری؛
- عدم تمرکز بر شناسایی خودرو مگر در حد تشریح چارچوب توسعه‌پذیری؛
- عدم پردازش پلاک‌های شدیداً مخدوش یا عمداً پنهان‌شده

و کیفیت (محلی یا کارت تسریع‌گر لبه GPU) فرضیات کلیدی شامل در دسترس بودن حداقلی از توان پردازشی معقول دوربین‌هاست.

9-1- تعاریف و اختصارات

- تشخیص خودکار پلاک خودر: ALPR
- ناحیه مورد علاقه/ناحیه هدف: AOI/ROI
- OCR شبکه‌های عصبی کانولوشنی /بازگشتی کانولوشنی برای: CNN/CRNN
- نرخ فریم بر ثانیه: FPS
- سخت‌افزار لبه با توان پردازشی محدود: Edge Device

10-1- روش کلی انجام پروژه

روش کلی کار در این پژوهش به‌صورت گام‌های زیر صورت‌بندی می‌شود:

- گردآوری و یکپارچه‌سازی داده‌ها از منابع جهانی و بومی؛ پاکسازی و بازبینی برچسب‌ها؛
- پیش‌پردازش شامل تصحیح نور و کنتراست، حذف نویز، هم‌مقیاس‌سازی، و افزایش داده هدفمند؛
- آموزش/ری‌آموزش مدل‌های آشکارساز با تنظیمات ابرپارامتر مناسب؛
- Tesseract یا CRNN با OCR پیاده‌سازی و کالیبراسیون حروف فارسی/لاتین؛
- Adaptive Model Switching طراحی مازول بر پایه شاخص‌های کیفیت و یک دسته‌بند سبک؛
- ارزیابی کمی و کیفی و تحلیل موازنه دقت/سرعت در سناریوهای واقعی.

11-1- مخاطرات، ملاحظات حقوقی و اخلاقی

به‌کارگیری سامانه‌های نظارتی نیازمند توجه جدی به حریم خصوصی شهروندان، نگهداری امن داده‌ها و رعایت قوانین جاری است. در این پژوهش، با هدف آزمایش علمی، تنها داده‌های عمومی یا داده‌های اخذشده با مجوز و ناشناس‌سازی مناسب استفاده می‌شود. دسترسی به نتایج باید مبتنی بر سطوح اختیار بوده و هرگونه استفاده عملیاتی منوط به مجوزهای قانونی است.

از منظر فنی نیز ریسک‌هایی مانند بیش‌برازش، سوگیری داده، و حملات خصمانه مطرح است که با طراحی صحیح مجموعه‌داده، افزایش‌داده متوازن، و ارزیابی فراگیر تا حد امکان مدیریت می‌شوند.

12-1- ساختار پایان‌نامه

ساختار این پایان‌نامه در فصل‌های بعدی به ترتیب شامل مبانی نظری و مرور تحقیقات پیشین، روش‌شناسی و طراحی سامانه، پیاده‌سازی عملی و جزئیات فنی، نتایج آزمایش‌ها و تحلیل، و در نهایت جمع‌بندی و پیشنهادات آتی است. این نقشه راه به خواننده کمک می‌کند تا ضمن درک چرایی و چگونگی انتخاب‌ها، مسیر تکوین سامانه را به‌صورت مرحله‌ای دنبال کند.

13-1- چشم‌انداز فنی و نقشه راه توسعه

در راستای پایداری و توسعه‌پذیری سامانه، چشم‌انداز زیر در نظر گرفته می‌شود:

- به‌کارگیری مدل‌های سبک‌وزن برای استقرار بر روی Edge ؛
- افزودن ماژول ردیابی جهت تثبیت خروجی‌ها در ویدئو؛
- کالیبراسیون تطبیقی برای شرایط محلی هر دوربین؛
- پایش سلامت مدل و به‌روزرسانی تدریجی برخط.

14-1- جمع‌بندی فصل

چالش‌های محیط واقعی و مسیر راه‌حل مبتنی ، ALPR در این فصل، ضمن تبیین اهمیت و ضرورت موضوع بر ترکیب مدل‌های عمیق و سوییچینگ تطبیقی تشریح شد. فصل‌های آتی به تفصیل جنبه‌های نظری، روش‌شناختی و اجرایی را دنبال خواهند کرد.

2- فصل دوم

2-1- مقدمه

هر پروژه پژوهشی علمی، به‌ویژه در حوزه‌های مهندسی و فناوری، نیازمند داشتن یک پایه نظری محکم و شناخت کافی از کارهای انجام‌شده پیشین است. مرور مبانی نظری نه‌تنها به پژوهشگر کمک می‌کند تا درک درستی از مفاهیم کلیدی و ابزارهای مورد استفاده پیدا کند، بلکه جایگاه دقیق پروژه را در میان تلاش‌های علمی موجود مشخص می‌سازد.

در زمینه تشخیص پلاک خودرو (ALPR)، طیف وسیعی از روش‌ها از تکنیک‌های سنتی پردازش تصویر تا الگوریتم‌های مدرن یادگیری عمیق توسعه یافته‌اند. هر یک از این روش‌ها نقاط قوت و ضعف خاص خود را دارند و بررسی آن‌ها به پژوهشگر نشان می‌دهد که کدام مسیرها به موفقیت منجر شده و کدام مسیرها با محدودیت‌های اساسی مواجه بوده‌اند.

اهمیت مرور مبانی نظری در این پروژه از چند جنبه قابل توجه است:

- شناخت مفاهیم پایه‌ای پردازش تصویر و بینایی ماشین: برای درک چرایی و چگونگی استفاده از شبکه‌های عصبی عمیق در ALPR، ابتدا باید با مفاهیم اولیه نظیر آستانه‌گذاری، فیلترگذاری، بخش‌بندی و استخراج ویژگی آشنا شد.
- پیوند نظریه و عمل: مبانی نظری، پلی میان مفاهیم انتزاعی و کاربردهای عملی فراهم می‌آورد. به کمک این فصل، خواننده درمی‌یابد که چطور تئوری‌های یادگیری عمیق و شبکه‌های عصبی به طراحی سامانه‌های واقعی تشخیص پلاک منجر می‌شوند.
- پرهیز از دوباره‌کاری: مرور تحقیقات پیشین مانع از تکرار خطاهای گذشته می‌شود و امکان تمرکز بر نوآوری‌های جدید را فراهم می‌سازد.
- ایجاد چارچوب مقایسه‌ای: با شناخت دستاوردها و نتایج پروژه‌های مشابه، می‌توان عملکرد سیستم پیشنهادی را به‌صورت عادلانه با آن‌ها مقایسه کرد.

در مجموع، این فصل نه‌تنها دانش لازم برای درک بهتر فصول بعدی را فراهم می‌کند، بلکه ارزش و ضرورت پروژه حاضر را نیز در زمینه علمی آن برجسته می‌سازد.

۲-۲ مفاهیم پایه‌ای پردازش تصویر

پردازش تصویر یکی از مهم‌ترین شاخه‌های بینایی ماشین است که هدف اصلی آن استخراج اطلاعات مفید از داده‌های تصویری برای تصمیم‌گیری و تحلیل است. اساس کار بسیاری از سیستم‌های هوشمند، از جمله تشخیص

پلاک خودرو (ALPR)، بر مبنای این حوزه علمی است. درک مفاهیم پایه‌ای پردازش تصویر برای طراحی هر سیستم تشخیص خودکار، به‌ویژه در شرایط متغیر محیطی، ضروری است.

1-2-2 مراحل پردازش تصویر

الف) پیش‌پردازش (Pre-Processing)

پیش‌پردازش، نخستین مرحله در پردازش تصویر است که هدف آن آماده‌سازی داده‌های خام تصویری برای مراحل بعدی است. بدون انجام این مرحله، احتمال کاهش دقت در بخش‌های بعدی وجود دارد. برخی از مهم‌ترین تکنیک‌های پیش‌پردازش عبارت‌اند از:

- نرمال‌سازی شدت روشنایی: با این روش می‌توان تصاویر گرفته‌شده در شرایط نوری مختلف (مثلاً روز و شب) را همسان‌سازی کرد.
- فیلترهای حذف نویز: فیلتر میانگین، گاوسی و میانه‌ای، برای کاهش نویزهای ناشی از کیفیت پایین دوربین یا شرایط محیطی استفاده می‌شوند.
- افزایش کنتراست: با استفاده از روش‌هایی مثل Histogram Equalization می‌توان تفاوت بین پس‌زمینه و جسم اصلی (پلاک) را برجسته کرد.
- تبدیل به سطوح خاکستری: این روش با کاهش داده‌های رنگی به شدت روشنایی، بار محاسباتی را کم کرده و تمرکز بر الگوهای ساختاری تصویر را ممکن می‌سازد.

ب) بخش‌بندی

بخش‌بندی به معنای جدا کردن اجسام یا نواحی خاص در تصویر است. در ALPR، مهم‌ترین وظیفه بخش‌بندی، جداسازی ناحیه پلاک از تصویر خودرو است.

روش‌های مهم در بخش‌بندی عبارت‌اند از:

- بخش‌بندی سراسری با آستانه‌گذاری: تعیین یک آستانه کلی یا تطبیقی برای جداکردن جسم از پس‌زمینه.
- بخش‌بندی مبتنی بر لبه: شناسایی مرزهای پلاک با استفاده از تغییرات ناگهانی شدت روشنایی.
- بخش‌بندی ناحیه‌ای: گروه‌بندی پیکسل‌ها با ویژگی‌های مشابه رنگ، شدت یا بافت.
- روش‌های مدرن‌تر: استفاده از خوشه‌بندی یا مدل‌های یادگیری عمیق

ج) استخراج ویژگی (Feature Extraction)

ویژگی‌ها، توصیف‌کننده خصوصیات تصویری هستند که امکان شناسایی یا طبقه‌بندی دقیق‌تر را فراهم می‌کنند. ویژگی‌های متداول عبارت‌اند از:

- ویژگی‌های هندسی: طول، عرض، نسبت ابعاد، و مساحت ناحیه پلاک.
- ویژگی‌های بافتی (Texture Features): که با الگوریتم‌هایی مثل Local Binary Patterns (LBP) استخراج می‌شوند.
- ویژگی‌های آماری: توزیع شدت روشنایی، هیستوگرام رنگ یا گرادیان‌ها.
- ویژگی‌های محلی: مانند HOG (Histogram of Oriented Gradients) و SIFT (Scale Invariant Feature Transform) که برای شناسایی الگوها کاربرد زیادی دارند.

(د) طبقه‌بندی (Classification)

مرحله پایانی پردازش تصویر، طبقه‌بندی داده‌ها بر اساس ویژگی‌های استخراج‌شده است. در ALPR، این بخش عمدتاً به تشخیص کاراکترهای پلاک مربوط می‌شود. در گذشته، الگوریتم‌های کلاسیک مانند K-Nearest Neighbors (KNN)، Support Vector Machines (SVM) و شبکه‌های عصبی ساده (MLP) به‌کار می‌رفتند. اما امروزه، مدل‌های یادگیری عمیق مانند CNN و CRNN جایگزین شده‌اند که دقت و پایداری بیشتری دارند.

۲-۲-۲. تکنیک‌های کلاسیک پردازش تصویر

پیش از ظهور یادگیری عمیق، بخش عمده‌ای از سیستم‌های پردازش تصویر بر پایه تکنیک‌های کلاسیک بنا شده بود. اگرچه این روش‌ها محدودیت‌هایی دارند، اما همچنان در بسیاری از سامانه‌ها و به‌ویژه در پیش‌پردازش ALPR کاربرد دارند.

۱. آستانه‌گذاری (Thresholding)

- یکی از ساده‌ترین و قدیمی‌ترین روش‌های بخش‌بندی تصویر.
- در این روش، شدت روشنایی پیکسل‌ها با یک مقدار آستانه مقایسه می‌شود؛ پیکسل‌های روشن‌تر به‌عنوان جسم و پیکسل‌های تیره‌تر به‌عنوان پس‌زمینه در نظر گرفته می‌شوند.
- آستانه‌گذاری تطبیقی (Adaptive Thresholding): برای شرایطی که نور تصویر یکنواخت نیست (مثلاً یک بخش روشن و بخش دیگر تاریک).

۲. فیلترگذاری (Filtering)

فیلترها نقش مهمی در کاهش نویز و استخراج ویژگی دارند:

- فیلتر گاوسی: کاهش نویز و هموارسازی تصویر.
 - فیلتر میانه‌ای: حذف نویزهای نمکی و فلفلی. (Salt & Pepper Noise)
 - فیلتر لاپلاسی: تقویت لبه‌ها.
 - فیلتر سوبل: تشخیص مرزها و خطوط افقی/عمودی.
۳. تشخیص لبه‌ها (Edge Detection)

لبه‌ها مهم‌ترین اطلاعات ساختاری در تصویر هستند و نقش مهمی در شناسایی مرز پلاک و کاراکترها دارند. روش‌های معروف عبارت‌اند از:

- Sobel و Prewit: تشخیص لبه‌های افقی و عمودی.
- Canny: یکی از قوی‌ترین الگوریتم‌ها که با ترکیب چند مرحله (حذف نویز، محاسبه گرادیان، نازک‌سازی لبه‌ها و آستانه‌گذاری دوگانه) دقت بالایی دارد.
- LoG (Laplacian of Gaussian): ترکیب فیلتر گاوسی و لاپلاسی برای یافتن لبه‌ها.

2-2-3- ارتباط روش‌های کلاسیک با یادگیری عمیق

هرچند امروزه شبکه‌های عصبی عمیق بسیاری از این مراحل (پیش‌پردازش، استخراج ویژگی و طبقه‌بندی) را به‌صورت خودکار و یکپارچه انجام می‌دهند، اما در عمل هنوز هم روش‌های کلاسیک در کنار یادگیری عمیق استفاده می‌شوند. به‌طور مثال:

- Adaptive Thresholding: برای بهبود ورودی مدل‌های یادگیری عمیق.
- عملیات مورفولوژیک برای اصلاح خروجی‌های مدل.
- تشخیص لبه‌ها برای نرمال‌سازی داده‌های ورودی.

۲-۳ شبکه‌های عصبی و یادگیری عمیق در بینایی ماشین

۲-۳-۱ معرفی شبکه‌های عصبی کانولوشنی (CNN)

شبکه‌های عصبی کانولوشنی (Convolutional Neural Networks) خانواده‌ای از مدل‌های یادگیری عمیق هستند که برای پردازش داده‌های تصویری و مکانی (Spatial) طراحی شده‌اند. ایده محوری در CNN، استفاده از فیلترهای کانولوشنی برای استخراج خودکار ویژگی‌ها از تصویر است؛ به‌گونه‌ای که لایه‌های اولیه الگوهای

ساده (لبه‌ها، گوشه‌ها، بافت‌های پایه) و لایه‌های عمیق‌تر مفاهیم پیچیده‌تر (اجزای اشیاء، ساختارهای معنایی) را می‌آموزند.

۲-۳-۲ ساختار معماری‌های معروف (LeNet, AlexNet, VGG, ResNet)

- **LeNet** : از نخستین CNN ها برای تشخیص رقم‌های دست‌نویس. ساختاری کم‌عمق با توالی کانولوشن- Pooling-Fully Connected که نشان داد CNN در بینایی ماشین چقدر مؤثر است.
- **AlexNet** : نقطه عطف رقابت. ImageNet. عمق بیشتر، استفاده از ReLU برای همگرایی سریع‌تر، Dropout برای مقابله با بیش‌برازش و Data Augmentation گسترده.
- **VGG** : تأکید بر فیلترهای کانولوشن 3×3 و افزایش عمق یکنواخت. اگرچه محاسبات سنگین است، اما سادگی و کیفیت ویژگی‌های استخراجی آن را محبوب کرده است.
- **ResNet** : معرفی اتصالات میان‌بری (Skip Connections) و بلوک‌های باقیمانده برای حل مشکل ناپایداری گرادیان در شبکه‌های بسیار عمیق. این معماری امکان آموزش صدها لایه را فراهم کرد و بنیان بسیاری از مدل‌های مدرن شد.

۲-۳-۳ کاربرد CNN در تشخیص اشیاء

CNN ها در تشخیص اشیاء (Object Detection) نقش بنیادین دارند. ایده اصلی، استخراج نگاشت‌های ویژگی قوی و سپس پیش‌بینی جعبه‌های مرزی (Bounding Boxes) و برچسب دسته برای هر شیء است. این کار یا به‌صورت دو مرحله‌ای تولید پیشنهاد ناحیه + طبقه‌بندی/ریگرسیون دقیق‌تر؛ مانند (Faster R-CNN یا تک‌مرحله‌ای پیش‌بینی مستقیم؛ مانند SSD و YOLO انجام می‌شود. در ALPR، CNN ها ابتدا ناحیه پلاک را کشف می‌کنند و سپس تصویر برش‌خورده پلاک برای OCR ارسال می‌شود.

۲-۴-۲ معماری‌های مدرن آشکارسازی پلاک

۲-۴-۱ معرفی YOLO نسخه‌های v3 تا v8

YOLO (You Only Look Once) خانواده‌ای از آشکارسازهای تک‌مرحله‌ای و بسیار سریع است که به‌صورت سراسری روی تصویر عمل کرده و مختصات جعبه‌های مرزی و برچسب‌ها را همزمان پیش‌بینی می‌کند.

- **YOLOv3** : استفاده از Darknet-53 و پیش‌بینی چندمقیاسی، توازن مناسب سرعت/دقت.
- **YOLOv5** : نسخه PyTorch با پشتیبانی از اندازه‌های مختلف (s/m/l/x)، آموزش آسان، Augmentation پیشرفته و استقرار ساده.

- **YOLOv7** : بهینه‌سازی‌های معماری/آموزشی؛ در بسیاری از سناریوها رکورددار FPS/دقت در زمان معرفی.
- **YOLOv8** : بازطراحی بخش‌هایی از ستون فقرات و Head ، بهبود آموزش، پشتیبانی بهتر از وظایف. در ALPR ، YOLO به‌خاطر سرعت بالا و سادگی استقرار روی Edge ، گزینه‌ای ممتاز برای آشکارسازی ناحیه پلاک است.

۲-۴-۲ SSD و Faster R-CNN

- **Faster R-CNN** : معماری دو مرحله‌ای با شبکه پیشنهاد ناحیه (RPN) ؛ عموماً دقیق‌تر از مدل‌های تک‌مرحله‌ای اما کندتر. مناسب سناریوهایی که دقت بیشینه نسبت به FPS اولویت دارد.
- **SSD (Single Shot MultiBox Detector)** : آشکارساز تک‌مرحله‌ای مبتنی بر نقشه‌های ویژگی چندمقیاسی؛ سرعت بالا با دقت قابل قبول. برای اشیای کوچک نیازمند تنظیم دقیق و داده‌ی کافی است.

۲-۴-۳ مقایسه دقت و سرعت

- **Faster R-CNN** : دقت بالا، سرعت کمتر؛ مناسب پردازش غیربلادرنگ یا سامانه‌های GPU قوی.
- **SSD** : سرعت بالا، دقت متوسط تا خوب؛ مناسب کاربردهای بلادرنگ سبک.
- **YOLOv5/v7/v8** : طیف وسیع نسخه‌ها برای موازنه دلخواه سرعت/دقت؛ نسخه‌های کوچک (s/n) برای Edge و نسخه‌های بزرگ (l/x) برای GPU های قدرتمند. برای ALPR عملیاتی (کنترل تردد، پارکینگ، جاده)، معمولاً YOLO به‌دلیل FPS بالا و سادگی پیاده‌سازی برتری دارد؛ در حالی‌که برای تحلیل‌های تحقیقاتی/آفلاین، Faster R-CNN می‌تواند دقت برتری ارائه کند.

۲-۵ OCR و شناسایی کاراکترها

۲-۵-۱ تاریخچه OCR (Tesseract)

OCR تشخیص نویسه نوری از دهه‌های گذشته برای تبدیل تصاویر متنی به متن دیجیتال به کار گرفته شده است. Tesseract یکی از معروفترین موتورهای متن‌باز OCR است که در نسخه‌های جدید با LSTM بهبود یافته و کیفیت تشخیص بهتری ارائه می‌دهد. مزیت اصلی آن سهولت استفاده و پشتیبانی از زبان‌های متعدد است. با

این حال، برای سناریوهای دشوار (نور بد، زاویه، اعوجاج) به پیش‌پردازش دقیق و گاهی آموزش سفارشی نیاز دارد.

۲-۵-۲ مدل‌های عمیق‌تر مثل CRNN

CRNN (Convolutional Recurrent Neural Network) معماری‌ای ترکیبی است:

1. **CNN** برای استخراج ویژگی‌های تصویری،
2. **RNN/LSTM/GRU** برای مدل‌کردن توالی افقی نویسه‌ها،
3. **CTC Loss** برای هم‌راستاسازی انعطاف‌پذیر ورودی/خروجی بدون نیاز به برچسب‌گذاری.
4. **CRNN** در پلاک‌خوانی، علائم راهنمایی، و متون طبیعی عملکرد بسیار خوبی دارد؛ به‌ویژه زمانی که با **Augmentation** مناسب آموزش داده شود.

۲-۵-۳ چالش‌های OCR برای زبان فارسی/پلاک‌های ایران

- **جهت‌نوشتار و فونت‌های خاص:** فارسی راست‌به‌چپ است و برخی حروف در پلاک‌ها شکل‌های خاص و نزدیک به هم دارند.
- **ترکیب حروف و اعداد:** وجود حروف فارسی/لاتین و اعداد هم‌زمان؛ نیاز به **کالیبراسیون** دقیق.
- **کیفیت پایین و اعوجاج هندسی:** نور چراغ‌ها، انعکاس، کج‌شدگی و محوشدگی حرکت.
- **تنوع ظاهری پلاک‌ها:** تفاوت ضخامت قلم، فاصله کاراکترها، وجود پیچ/پلمپ.
- **راهکارها:** پیش‌پردازش قوی و آموزش/آموزش مدل روی داده‌های بومی، **Language Model/Dictionary** برای تصحیح خروجی، و پس‌پردازش **قاعده‌محور** و قوانین قالب پلاک ایران.

۲-۶ کارهای مرتبط و تحقیقات پیشین

۲-۶-۱ پروژه‌ها و مقالات بین‌المللی

در ادبیات جهانی، تکامل **ALPR** از روش‌های کلاسیک (آستانه‌گذاری، لبه‌یابی، **HOG+SVM** به مدل‌های عمیق (**Faster R-CNN/SSD/YOLO + CRNN**) به‌خوبی مستند شده است.

- بسیاری از کارها نشان داده‌اند آشکارسازی **چندمقیاسی** و **Augmentation هدفمند** برای نور/زاویه/نویز، دقت سیستم را به‌طور محسوس افزایش می‌دهد.
- در **OCR**، حرکت از **Tesseract** کلاسیک به **CRNN/LSTM** باعث بهبود پایداری در شرایط واقعی شده است.

- تلاش‌های جدید به سمت **End-to-End ALPR** از تصویر خام تا متن پلاک در یک مدل و نیز بهره‌گیری از مدل‌های سبک برای Edge رفته‌اند.

۲-۶-۲ پروژه‌های داخلی و سامانه‌های فعلی در ایران

در ایران، سامانه‌های کنترل طرح ترافیک، پارکینگ‌های بزرگ، و برخی سامانه‌های پلیس از ALPR استفاده می‌کنند. بخش قابل توجهی از راهکارها یا ترکیبی کلاسیک + عمیق هستند یا بر مدل‌های آماده خارجی تکیه دارند. چالش‌های محلی شامل نور شب/تابلوه‌های بازتابنده، تنوع فونت و قالب پلاک‌ها، و کیفیت دوربین‌های نظارتی است. پژوهش‌های داخلی به‌طور فزاینده به سمت **YOLO + Tesseract/CRNN** با داده‌های بومی حرکت کرده‌اند.

۲-۶-۳ تحلیل نقاط ضعف و قوت

- **قوت‌ها:** دسترسی گسترده به فریم‌ورک‌ها (PyTorch/TensorFlow)، وجود مدل‌های پایه آماده، تجربه عملیاتی در سیستم‌های شهری.
- **ضعف‌ها:** کمبود دیتاست‌های بومی با تنوع بالا و برجسب دقیق، وابستگی به سخت‌افزارهای خاص، نبود معیارسنجی استاندارد و جامع، و عدم مستندسازی باز برای ارزیابی مقایسه‌ای.
- **فرصت‌ها:** ساخت مخزن داده بومی، طراحی ماژول سوئیچینگ تطبیقی، بهینه‌سازی برای Edge، و تعریف پروتکل‌های ارزیابی شفاف برای سنجش واقعی.
- **تهدیدها:** مسائل حریم خصوصی و امنیت داده، پلاک‌های مخدوش/جعلی، حملات خصمانه یادگیری ماشین (Adversarial).

۲-۷ جمع‌بندی فصل

در این فصل، مروری جامع بر مبانی نظری و کارهای پیشین در حوزه تشخیص پلاک خودرو (ALPR) ارائه شد. مباحث مطرح‌شده را می‌توان در دو محور اصلی خلاصه کرد:

۲-۷-۱ نکات کلیدی مبانی نظری

1. پردازش تصویر کلاسیک: روش‌های سنتی نظیر آستانه‌گذاری، فیلترگذاری، عملیات مورفولوژیک و تشخیص لبه‌ها، زیربنای اولیه بسیاری از سامانه‌های ALPR بودند. این روش‌ها اگرچه در شرایط کنترل‌شده کارآمد هستند، اما در محیط‌های واقعی دچار ضعف می‌شوند.

2. شبکه‌های عصبی کانولوشنی: ورود CNN ها نقطه عطفی در بینایی ماشین بود. معماری‌هایی همچون LeNet، AlexNet، VGG و ResNet نشان دادند که یادگیری عمیق می‌تواند ویژگی‌های پیچیده تصویری را به‌صورت خودکار استخراج کند.

3. مدل‌های آشکارسازی مدرن: الگوریتم‌های YOLO و SSD و Faster R-CNN امکان آشکارسازی سریع و دقیق ناحیه پلاک را فراهم ساخته‌اند. مقایسه‌ها نشان می‌دهد که YOLO در کاربردهای بلادرنگ برتری دارد، در حالی‌که Faster R-CNN دقت بالاتری در شرایط غیر بلادرنگ دارد.

4. OCR و شناسایی کاراکترها: سیستم‌های کلاسیکی مانند Tesseract پایه‌گذار OCR بودند، اما معماری‌های مدرن CRNN توانسته‌اند بر محدودیت‌های آن غلبه کنند. چالش‌های OCR در زبان فارسی (فونت‌های خاص، ترکیب حروف و اعداد، راست‌به‌چپ بودن نوشتار) نیازمند داده‌های بومی و پیش‌پردازش‌های ویژه است.

5. کارهای پیشین: در سطح بین‌المللی، حرکت از روش‌های کلاسیک به سمت معماری‌های عمیق و حتی مدل‌های End-to-End مشهود است. در ایران نیز استفاده از YOLO و OCR ترکیبی در سامانه‌های شهری آغاز شده، اما همچنان ضعف در تنوع داده‌های بومی و کمبود ارزیابی‌های استاندارد وجود دارد.

۲-۷-۲ جایگاه پروژه در میان پژوهش‌های قبلی

پروژه حاضر بر پایه همین مبانی و با الهام از تحقیقات گذشته طراحی شده است، اما چندین نوآوری کلیدی دارد که آن را از پژوهش‌های پیشین متمایز می‌سازد:

- بهره‌گیری هم‌زمان از چند معماری آشکارسازی طراحی مکانیزم **Adaptive Model Switching** برای انتخاب مدل مناسب در شرایط مختلف.
- تمرکز ویژه بر **داده‌های بومی** ایران و ترکیب آن‌ها با دیتاست‌های جهانی برای افزایش پایداری سامانه.
- پیاده‌سازی OCR پیشرفته با استفاده از CRNN یا Tesseract اصلاح‌شده، متناسب با ویژگی‌های زبان فارسی.
- توجه به **استقرار عملیاتی** روی سخت‌افزارهای لبه (Edge Devices) به‌منظور دستیابی به اجرای بلادرنگ.

در نتیجه، جایگاه این پروژه در مرز میان پژوهش‌های نظری و کاربردی است؛ از یک‌سو بر پایه دستاوردهای علمی روز استوار است، و از سوی دیگر با در نظر گرفتن نیازها و محدودیت‌های محیطی کشور، قابلیت عملیاتی و اجرایی بالایی دارد.

فصل سوم

۳-۱- مقدمه

در این فصل، به تشریح روش تحقیق و مراحل اجرای پروژه پرداخته می‌شود. هدف اصلی این فصل، ارائه یک نقشه راه روشن از روند توسعه سامانه تشخیص پلاک خودرو (ALPR) است؛ به گونه‌ای که مراحل اجرایی از جمع‌آوری داده‌ها تا طراحی مکانیزم سوییچینگ تطبیقی به صورت گام‌به‌گام بیان شود.

یکی از ویژگی‌های پروژه حاضر، ترکیب مفاهیم نظری با پیاده‌سازی عملی است. به همین دلیل، علاوه بر معرفی الگوریتم‌ها و مدل‌های مورد استفاده، ابزارها، چارچوب‌های نرم‌افزاری، و مراحل پردازشی نیز به طور کامل توضیح داده خواهد شد. همچنین، در طول فصل تلاش می‌شود منطق انتخاب هر روش، مزایا و محدودیت‌های آن، و چگونگی یکپارچه‌سازی آن‌ها در قالب یک سامانه کامل مورد بررسی قرار گیرد.

در واقع این فصل، پلی است میان مباحث نظری فصل دوم و نتایج عملی فصل چهارم و پنجم؛ یعنی نشان می‌دهد که چگونه مبانی علمی به روش‌های اجرایی و پیاده‌سازی واقعی ترجمه شده‌اند.

۳-۲- مراحل کلی انجام پروژه

روند کلی اجرای پروژه را می‌توان به پنج گام اصلی تقسیم کرد:

۳-۲-۱- جمع‌آوری و آماده‌سازی داده‌ها

پایه و اساس موفقیت هر پروژه یادگیری عمیق، کیفیت و کمیت داده‌های آموزشی است. در این مرحله:

- از دیتاست‌های جهانی مانند CCPD (Chinese City Parking Dataset) و AOLP (Taiwan License Plate Dataset) استفاده شد.
- تصاویر بومی از پلاک‌های خودروهای ایرانی گردآوری شد تا مدل قابلیت سازگاری با شرایط واقعی کشور را پیدا کند.
- فرآیند لیبل‌گذاری (Annotation) برای تعیین ناحیه پلاک و کاراکترها انجام شد.
- با استفاده از تکنیک‌های Data Augmentation نظیر چرخش، تغییر روشنایی، محو کردن و افزودن نویز، مجموعه داده غنی‌تر و متنوع‌تر گردید.

۳-۲-۲- پیش‌پردازش تصاویر

هدف این مرحله، بهبود کیفیت تصاویر و آماده‌سازی آن‌ها برای ورود به مدل‌های یادگیری عمیق است. برخی از گام‌های اصلی عبارت‌اند از:

- اصلاح روشنایی و کنتراست برای سازگاری تصاویر در شرایط نوری مختلف.
- حذف نویز با استفاده از فیلترهای میانگین و گاوسی.
- نرمال‌سازی ابعاد به اندازه استاندارد مورد نیاز مدل‌ها.
- استفاده از Adaptive Thresholding برای جداسازی بهتر ناحیه پلاک در شرایط نوری سخت.

۳-۲-۳- آموزش و ارزیابی مدل‌های آشکارساز (YOLOv5, YOLOv8, Faster R-CNN)

در این پروژه سه معماری مدرن برای آشکارسازی پلاک مورد استفاده قرار گرفتند:

- YOLOv5 : به دلیل سرعت بالا و سادگی استقرار روی Edge=
 - YOLOv8 : به عنوان نسخه بهبود یافته و مدرن‌تر YOLO=
 - Faster R-CNN : به دلیل دقت بالا، هرچند با هزینه محاسباتی بیشتر.
- هر مدل با داده‌های بومی و ترکیبی آموزش داده شد و عملکرد آن‌ها با معیارهایی مانند دقت (Precision) ، یادآوری (Recall) ، F1-Score و mAP (mean Average Precision) ارزیابی گردید.

۳-۲-۴- پیاده‌سازی OCR یا CRNN یا Tesseract

پس از آشکارسازی ناحیه پلاک، مرحله بعدی استخراج کاراکترها است. در این پروژه دو رویکرد به کار گرفته شد:

- Tesseract OCR : به عنوان یک ابزار قدرتمند و ساده برای تشخیص متن، با سفارشی‌سازی برای پلاک‌های فارسی.
 - CRNN : یک معماری یادگیری عمیق متشکل از CNN برای استخراج ویژگی‌ها، RNN برای مدل‌سازی توالی کاراکترها و CTC Loss برای همراستاسازی ورودی و خروجی.
- مقایسه عملکرد این دو روش نشان می‌دهد که CRNN در شرایط دشوار (نور کم یا زاویه غیرعادی) نتایج بهتری ارائه می‌دهد، در حالی که Tesseract در پردازش سریع و ساده مؤثر است.

۳-۲-۵- طراحی مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)

نوآوری اصلی پروژه، طراحی یک سیستم هوشمند است که بسته به شرایط ورودی، بهترین مدل آشکارساز یا OCR را انتخاب می‌کند.

- در این مکانیزم، شاخص‌هایی مانند روشنایی تصویر، میزان وضوح، زاویه پلاک و سطح نویز اندازه‌گیری می‌شوند.

- بر اساس این شاخص‌ها، سیستم تصمیم می‌گیرد از کدام مدل YOLOv5 ، YOLOv8 یا Faster R-CNN استفاده کند.

- در نهایت، نتایج خروجی با الگوریتم‌های پس‌پردازش ترکیب و بهینه می‌شوند تا بیشترین دقت و پایداری حاصل گردد.

این مکانیزم تطبیقی، تضمین می‌کند که سامانه در طیف وسیعی از شرایط محیطی (روز/شب، زوایای مختلف، کیفیت پایین تصاویر) عملکرد پایدار و قابل اعتمادی داشته باشد.

۳-۳- جمع‌آوری و آماده‌سازی داده‌ها

کیفیت و تنوع داده‌ها یکی از عوامل اصلی در موفقیت سیستم‌های مبتنی بر یادگیری عمیق است. حتی پیشرفته‌ترین معماری‌های شبکه‌های عصبی نیز در صورتی‌که داده‌های آموزشی مناسب و کافی در اختیار نداشته باشند، نمی‌توانند عملکرد مطلوبی داشته باشند. به همین دلیل، در این پروژه زمان و تلاش زیادی برای گردآوری، لیبل‌گذاری، و آماده‌سازی داده‌ها صرف شد.

۳-۳-۱- معرفی دیتاست‌های جهانی

در سطح بین‌المللی، دیتاست‌های مختلفی برای تشخیص پلاک خودرو توسعه یافته‌اند. از جمله این دیتاست‌ها می‌توان به موارد زیر اشاره کرد:

- CCPD (Chinese City Parking Dataset) : یکی از بزرگ‌ترین دیتاست‌های پلاک خودرو با بیش از ۲۰۰ هزار تصویر. این دیتاست حاوی شرایط متنوع نوری، زوایای و محیطی است و در بسیاری از پژوهش‌ها به‌عنوان مرجع استفاده می‌شود.

- AOLP (Taiwan License Plate Dataset) : شامل بیش از ۲۰ هزار تصویر از پلاک‌های تایوانی در شرایط مختلف.

- OpenALPR Dataset : مجموعه‌ای از تصاویر خودرو در کشورهای مختلف برای آموزش سامانه‌های عمومی ALPR.

هرچند این دیتاست‌ها ارزش علمی و پژوهشی بالایی دارند، اما برای پلاک‌های ایران مناسب نیستند. تفاوت در زبان، فونت، رنگ، ابعاد و قالب نوشتاری باعث می‌شود که مدل‌های آموزش‌دیده روی این دیتاست‌ها، در شرایط بومی دچار افت دقت شوند. در پروژه حاضر، این دیتاست‌ها صرفاً به‌عنوان منابع مرجع برای مرور و مقایسه در نظر گرفته شدند و داده‌های اصلی به‌طور کامل از محیط واقعی ایران گردآوری شدند.

۳-۳-۲- جمع‌آوری تصاویر بومی (پلاک‌های ایرانی)

یکی از دستاوردهای مهم پروژه، تهیه یک دیتاست بومی اختصاصی از پلاک خودروهای ایرانی بود. این مجموعه داده شامل تصاویر متنوع از خودروها در شرایط مختلف است که توسط پژوهشگر گردآوری شده است. منابع اصلی جمع‌آوری داده عبارت‌اند از:

- وبسایت‌های خرید و فروش خودرو مانند دیوار و شیپور: این وبسایت‌ها حاوی هزاران تصویر واقعی از خودروهای مختلف هستند. در بسیاری از این تصاویر، پلاک خودرو قابل مشاهده است. با انتخاب و پالایش تصاویر مناسب، بخشی از دیتاست پروژه تهیه شد.
- تصاویر خیابانی: بخش دیگری از داده‌ها از طریق تصویربرداری مستقیم از خودروها در سطح خیابان و محیط‌های عمومی جمع‌آوری شد. این تصاویر شامل شرایط نوری متنوع (روز، شب، سایه، بارانی) و زوایای مختلف دوربین هستند.
- جمع‌آوری داده‌های بومی، امکان آموزش و ارزیابی دقیق‌تر مدل‌ها را فراهم می‌سازد و باعث می‌شود سامانه نهایی در شرایط واقعی کشور عملکرد قابل اعتمادی داشته باشد.

۳-۳-۳- فرآیند لیبل‌گذاری و یکپارچه‌سازی

پس از گردآوری داده‌ها، تمامی تصاویر باید لیبل‌گذاری شوند. این فرآیند برای شبکه‌های یادگیری عمیق ضروری است، زیرا مدل تنها از طریق داده‌های برچسب‌دار می‌تواند روابط میان تصویر و خروجی مورد انتظار را بیاموزد.

- در مرحله اول، ناحیه پلاک با استفاده از Bounding Box مشخص شد.
- در برخی تصاویر با کیفیت بالا، کاراکترهای داخل پلاک نیز به‌طور مجزا لیبل‌گذاری شدند تا امکان آموزش مدل‌های OCR دقیق‌تر فراهم گردد.
- ابزارهایی مانند LabelImg و Roboflow برای سهولت لیبل‌گذاری به‌کار گرفته شدند.
- داده‌های لیبل‌گذاری‌شده در قالب فرمت‌های استاندارد مانند YOLO TXT یا Pascal VOC XML ذخیره شدند.
- برای جلوگیری از بیش‌برازش، داده‌ها به سه بخش تقسیم شدند: ۷۰٪ برای آموزش، ۲۰٪ برای اعتبارسنجی و ۱۰٪ برای آزمون.

این فرآیند باعث شد مجموعه داده نهایی یکپارچه، استاندارد و آماده برای آموزش مدل‌ها باشد.

۳-۳-۴- تکنیک‌های Data Augmentation

با توجه به محدودیت تعداد تصاویر جمع‌آوری‌شده، برای افزایش حجم و تنوع داده‌ها از تکنیک‌های Data Augmentation استفاده شد. این تکنیک‌ها امکان شبیه‌سازی شرایط مختلف محیطی و نوری را فراهم می‌کنند و به بهبود تعمیم‌پذیری مدل کمک می‌نمایند.

روش‌های مورد استفاده در این پروژه عبارت‌اند از:

- چرخش (Rotation): برای سازی زوایای مختلف خودرو نسبت به دوربین.
 - تغییر روشنایی و کنتراست: برای بازتولید شرایط نور روز، شب یا سایه.
 - افزودن نویز (Noise): شبیه‌سازی کیفیت پایین دوربین یا تصاویر ارسال‌شده در شبکه.
 - محو کردن (Blur): بازتولید شرایط ناشی از حرکت سریع خودرو یا لرزش دوربین.
 - برش تصادفی (Random Cropping): واداشتن مدل به شناسایی پلاک در شرایطی که تنها بخشی از خودرو در تصویر دیده می‌شود.
 - وارونگی و تغییر رنگ: برای افزایش مقاومت مدل نسبت به تغییرات ظاهری.
- استفاده از این روش‌ها موجب شد مدل‌ها در برابر شرایط واقعی مانند نور ضعیف شب، کیفیت پایین تصاویر دوربین‌های شهری یا تغییر زاویه دوربین عملکرد بهتری از خود نشان دهند.

۳-۴- پیش‌پردازش تصاویر

پیش‌پردازش تصاویر، یکی از مراحل حیاتی در طراحی سامانه‌های ALPR است. داده‌های خامی که از دوربین‌ها یا منابع اینترنتی به دست می‌آیند معمولاً دارای کیفیت یکنواخت نیستند؛ تغییرات نور، نویز حسگرها، لرزش، و تفاوت در ابعاد تصاویر می‌تواند عملکرد مدل را تضعیف کند. به همین دلیل، مجموعه‌ای از تکنیک‌های پیش‌پردازش برای بهبود کیفیت داده‌ها و آماده‌سازی آن‌ها جهت ورود به مدل‌های یادگیری عمیق به‌کار گرفته شد.

۳-۴-۱- اصلاح روشنایی و کنتراست

یکی از مهم‌ترین چالش‌ها در تصاویر خیابانی، تغییرات شدید نور محیط است. پلاک خودرو ممکن است در نور مستقیم خورشید بیش از حد روشن یا در سایه بسیار تاریک دیده شود. برای رفع این مشکل، از روش‌هایی مانند:

- Histogram Equalization برای توزیع یکنواخت شدت روشنایی،
- CLAHE (Contrast Limited Adaptive Histogram Equalization) برای افزایش محلی کنتراست استفاده شد.

این روش‌ها کمک کردند کاراکترهای پلاک حتی در شرایط نوری دشوار به‌خوبی آشکار شوند.

۳-۴-۲- نرمال‌سازی ابعاد

مدل‌های یادگیری عمیق به ورودی‌هایی با ابعاد مشخص نیاز دارند. تصاویر جمع‌آوری‌شده از منابع مختلف، ابعاد متفاوتی داشتند. برای یکپارچه‌سازی، تمامی تصاویر به اندازه استاندارد 416×416 پیکسل برای YOLO یا

۶۰۰×۶۰۰ پیکسل برای Faster R-CNN تغییر مقیاس داده شدند. این نرمال‌سازی علاوه بر کاهش بار محاسباتی، باعث شد ویژگی‌های استخراج‌شده توسط شبکه‌ها قابل مقایسه باشند.

۳-۴-۳- حذف نویز

نویز در تصاویر می‌تواند ناشی از کیفیت پایین دوربین یا شرایط محیطی باشد. برای کاهش نویز، از فیلترهای مختلفی استفاده شد:

- Gaussian Filter حذف نویزهای نرم.
- Median Filter حذف نویز نمکی و فلفلی. (Salt & Pepper)
- Bilateral Filter حذف نویز همراه با حفظ لبه‌ها.

۳-۴-۴- استفاده از Adaptive Thresholding

یکی از روش‌های مؤثر برای جداسازی پلاک از پس‌زمینه، آستانه‌گذاری تطبیقی است. برخلاف آستانه‌گذاری ساده، در این روش برای هر بخش از تصویر مقدار آستانه به‌طور محلی محاسبه می‌شود. این ویژگی باعث می‌شود حتی در تصاویر با نور غیریکنواخت، ناحیه پلاک به‌طور دقیق‌تری شناسایی شود.

۳-۵- آموزش و ارزیابی مدل‌ها

۳-۵-۱- YOLOv5 و YOLOv8

مدل‌های YOLO به دلیل سرعت بالا و ساختار ساده، یکی از بهترین گزینه‌ها برای ALPR هستند. در این پروژه:

- YOLOv5 : با نسخه‌های مختلف (s/m/l/x) آموزش داده شد.
- YOLOv8 : به‌عنوان نسل جدید YOLO، با بهبودهایی در ستون فقرات (Backbone) و بخش خروجی (Head)، دقت بالاتری در شناسایی پلاک‌ها ارائه داد.

ابزارها=

- Batch Size: ۱۶ تا ۳۲
- Learning Rate: 0.001
- Optimizer: Adam/SGD
- Epochs: ۱۰۰-۱۵۰

LossFunction:

ترکیبی از سه بخش بود:

- **Localization Loss** برای مختصات جعبه‌ها
- **Confidence Loss** برای احتمال وجود پلاک
- **Classification Loss** برای نوع پلاک یا کلاس هدف

Faster R-CNN-۲-۵-۳

Faster R-CNN یک معماری دو مرحله‌ای است:

- در گام نخست، شبکه **RPN (Region Proposal Network)** نواحی احتمالی پلاک را پیشنهاد می‌دهد.
 - در گام دوم، این نواحی توسط شبکه اصلی دسته‌بندی و مکان‌یابی دقیق‌تر می‌شوند.
- این معماری اگرچه کندتر از **YOLO** است، اما در شرایط پیچیده (مانند پلاک‌های مخدوش یا زاویه‌دار) دقت بالاتری ارائه می‌دهد.

۳-۵-۳- معیارهای ارزیابی

برای ارزیابی عملکرد مدل‌ها، از معیارهای زیر استفاده شد:

- **Accuracy** : نسبت تعداد پیش‌بینی‌های درست به کل پیش‌بینی‌ها.
- **Precision** : درصد پلاک‌های درست شناسایی‌شده از میان تمام پلاک‌های تشخیص‌داده‌شده.
- **Recall** : درصد پلاک‌های درست شناسایی‌شده از میان تمام پلاک‌های واقعی.
- **F1-Score** : میانگین موزون **Precision** و **Recall**.
- **mAP (mean Average Precision)** : معیار اصلی در تشخیص اشیا که دقت مدل در تمام کلاس‌ها و سطوح آستانه را می‌سنجد.

۳-۶ - OCR و شناسایی کاراکترها

۳-۶-۱ - استفاده از CRNN

مدل **CRNN (Convolutional Recurrent Neural Network)** ترکیبی از سه بخش اصلی است:

- **CNN** : برای استخراج ویژگی‌های تصویری از کاراکترها.
- **RNN** : برای مدل‌سازی توالی کاراکترها.
- **CTC Loss (Connectionist Temporal Classification)** : برای هم‌راستاسازی خروجی بدون نیاز به برچسب‌گذاری دقیق کاراکتر به کاراکتر.

این معماری در پلاک‌خوانی بسیار کارآمد است، زیرا قادر است کاراکترهای متوالی در شرایط اعوجاج و نویز را تشخیص دهد.

۳-۶-۲ - معرفی Tesseract و آموزش سفارشی روی داده‌های فارسی

Tesseract یکی از قدیمی‌ترین و قدرتمندترین ابزارهای متن‌باز **OCR** است. در این پروژه، با استفاده از مدل‌های آموزش‌دیده بر روی حروف فارسی و اعداد ایرانی، **Tesseract** برای پلاک‌های بومی سفارشی‌سازی شد. این کار باعث شد که دقت خواندن کاراکترها در شرایط عادی بهبود یابد.

۳-۶-۳ - مقایسه عملکرد CRNN و Tesseract

- **Tesseract** : سرعت بالاتر، نیاز کمتر به منابع محاسباتی، اما حساس‌تر به نویز و شرایط نوری.
- **CRNN** : دقت بالاتر در شرایط سخت (نور شب، پلاک مخدوش)، اما نیازمند آموزش بیشتر و منابع محاسباتی قوی‌تر.

۳-۷ - مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)

۳-۷-۱ - ایده اصلی

نوآوری اصلی پروژه، طراحی یک مکانیزم هوشمند است که بسته به کیفیت تصویر ورودی، مدل بهینه برای آشکارسازی و **OCR** انتخاب می‌شود. به این ترتیب، سیستم در طیف وسیعی از شرایط محیطی عملکرد پایداری خواهد داشت.

۳-۷-۲ - معیارهای انتخاب

- روشنایی تصویر : در نور کم، استفاده از مدل‌هایی که به‌خوبی آموزش دیده‌اند.

- وضوح تصویر: در تصاویر کم‌کیفیت، مدل‌های مقاوم‌تر انتخاب می‌شوند.
- زاویه دید: در زاویه‌های غیرمستقیم، CRNN برای OCR نتایج بهتری دارد.

۳-۷-۳- الگوریتم تصمیم‌گیری

دو رویکرد برای انتخاب مدل در نظر گرفته شد:

1. Rule-Based: تعریف قوانین ساده بر اساس شاخص‌های کیفیت.
 2. ML-Based: استفاده از یک دسته‌بند سبک (مانند Random Forest یا شبکه عصبی کوچک) که کیفیت تصویر را تحلیل کرده و مدل مناسب را پیشنهاد می‌دهد.
- این مکانیزم تطبیقی، نقطه تمایز اصلی پروژه حاضر است و سبب می‌شود سامانه ALPR پیشنهادی حتی در شرایط دشوار عملیاتی نیز دقت بالایی داشته باشد.

۳-۸- جمع‌بندی فصل سوم

در این فصل، روند طراحی و مراحل اصلی اجرای پروژه سامانه تشخیص پلاک خودرو (ALPR) به‌طور جامع بررسی شد. همان‌طور که بیان گردید، فرآیند توسعه این سامانه از چند گام اساسی تشکیل می‌شود. ابتدا با گردآوری داده‌های بومی و واقعی از منابع مختلف (وبسایت‌های داخلی و تصاویر محیطی) و آماده‌سازی آن‌ها از طریق لیب‌گذاری دقیق و به‌کارگیری تکنیک‌های افزایش داده (Data Augmentation)، یک مجموعه داده استاندارد و متنوع تهیه شد. سپس، با استفاده از روش‌های پیش‌پردازش شامل اصلاح روشنایی و کنتراست، نرمال‌سازی ابعاد، حذف نویز و استانداردسازی تطبیقی، کیفیت تصاویر برای ورود به مدل‌های یادگیری عمیق بهبود یافت.

در ادامه، آموزش و ارزیابی سه معماری مدرن آشکارسازی یعنی YOLOv5، YOLOv8 و Faster R-CNN به‌صورت مجزا انجام شد. عملکرد این مدل‌ها بر اساس معیارهای متداول مانند دقت (Accuracy)، یادآوری (Recall)، دقت مثبت (Precision)، امتیاز F1 و میانگین دقت (mAP) مقایسه گردید. نتایج اولیه نشان داد که YOLO در شرایط عادی و بلادرنگ کارایی بالایی دارد، در حالی که Faster R-CNN در شرایط پیچیده دقت بیشتری ارائه می‌کند.

برای شناسایی کاراکترهای پلاک، دو رویکرد Tesseract OCR و مدل CRNN به‌کار گرفته شد. هر یک از این روش‌ها نقاط قوت و محدودیت‌های خاص خود را دارند؛ Tesseract سرعت و سادگی بیشتری دارد، در حالی که CRNN در مواجهه با تصاویر دشوار عملکرد دقیق‌تری ارائه می‌دهد.

در نهایت، نوآوری پروژه با معرفی مکانیزم Adaptive Model Switching تحقق یافت؛ سیستمی که قادر است بر اساس شاخص‌های کیفیت تصویر مانند روشنایی، وضوح و زاویه دید، بهترین مدل آشکارساز و OCR را انتخاب نماید. این مکانیزم، تضمین‌کننده‌ی پایداری عملکرد سامانه در شرایط متنوع و واقعی است.

به‌طور کلی، این فصل مسیر حرکت از داده‌های خام تا طراحی معماری کلی سامانه را روشن ساخت. در فصل چهارم، بر مبنای این نقشه راه، جزئیات پیاده‌سازی عملی، ابزارها و کدنویسی پروژه تشریح خواهد شد تا فرآیند نظری ارائه‌شده به مرحله اجرا در محیط واقعی منتقل شود.

فصل چهارم

۴-۱- مقدمه

پس از مرور مبانی نظری (فصل دوم) و تشریح روش تحقیق و مراحل اجرایی پروژه (فصل سوم)، در این فصل به بررسی پیاده‌سازی عملی سامانه تشخیص پلاک خودرو (ALPR) پرداخته می‌شود. هدف اصلی این فصل، توضیح دقیق جزئیات فنی و ابزارهای مورد استفاده در طراحی و توسعه سامانه است تا روند حرکت از ایده به محصول نهایی به‌طور شفاف برای خواننده ترسیم گردد.

در این فصل ابتدا محیط‌های توسعه و ابزارهای نرم‌افزاری و سخت‌افزاری مورد استفاده معرفی می‌شوند. سپس، نحوه پیاده‌سازی هر یک از ماژول‌های اصلی سیستم شامل پیش‌پردازش تصاویر، آشکارسازی پلاک، شناسایی کاراکترها (OCR) و در نهایت مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching) به‌طور گام‌به‌گام تشریح خواهد شد. افزون بر این، پیاده‌سازی یک اپلیکیشن تحت وب ساده با استفاده از چارچوب Flask به‌عنوان رابط کاربری برای سامانه نیز توضیح داده می‌شود.

نکته قابل توجه این است که طراحی سیستم حاضر تنها بر پایه استفاده از الگوریتم‌های از پیش آماده صورت نگرفته است، بلکه در بخش‌های متعددی شامل آموزش مجدد (Fine-Tuning) مدل‌های یادگیری عمیق بر روی داده‌های بومی، سفارشی‌سازی OCR برای زبان فارسی، و طراحی یک مکانیزم تصمیم‌گیری تطبیقی، نوآوری‌هایی ارائه گردیده است.

به‌طور خلاصه، فصل چهارم نشان می‌دهد که چگونه مبانی نظری و روش‌های انتخاب‌شده در فصل‌های پیشین، در عمل به یک سامانه کاربردی تبدیل شده‌اند. این فصل در واقع پلی است میان روش تحقیق و نتایج آزمایش‌ها؛ به‌گونه‌ای که مقدمات ورود به فصل پنجم (ارزیابی عملکرد و تحلیل نتایج) را فراهم می‌سازد.

۴-۲- ابزارها و محیط توسعه

انتخاب ابزارها و محیط‌های مناسب برای توسعه و پیاده‌سازی سامانه‌های مبتنی بر یادگیری عمیق از اهمیت بالایی برخوردار است. ابزارها و چارچوب‌های به‌کار گرفته‌شده در این پروژه، به‌گونه‌ای انتخاب شدند که ضمن فراهم آوردن قابلیت‌های محاسباتی پیشرفته، امکان توسعه سریع، آزمایش آسان، و استقرار عملیاتی را نیز فراهم کنند. در ادامه، جزئیات هر یک از این ابزارها و محیط‌ها بیان می‌شود.

۴-۲-۱- زبان برنامه‌نویسی (Python)

زبان Python به‌عنوان اصلی‌ترین زبان برنامه‌نویسی در پروژه انتخاب شد. دلیل این انتخاب عبارت است از:

- سادگی و خوانایی بالا که توسعه سریع نمونه‌های اولیه را ممکن می‌سازد.

- وجود کتابخانه‌های قدرتمند در حوزه پردازش تصویر، یادگیری ماشین و یادگیری عمیق.
- جامعه کاربری گسترده و پشتیبانی عالی در مستندات و انجمن‌ها.
- قابلیت یکپارچه‌سازی با محیط‌های وب (Flask/Django) و سخت‌افزارهای لبه.

۴-۲-۲- کتابخانه‌ها

برای اجرای بخش‌های مختلف پروژه، از مجموعه‌ای از کتابخانه‌های تخصصی استفاده شد:

- OpenCV : کتابخانه‌ای قدرتمند برای پردازش تصویر و بینایی ماشین؛ استفاده در پیش‌پردازش، فیلترگذاری، بخش‌بندی، و نمایش نتایج.
- PyTorch : چارچوب یادگیری عمیق برای آموزش و پیاده‌سازی مدل‌های YOLOv5 و YOLOv8. این کتابخانه به دلیل انعطاف‌پذیری بالا و سرعت اجرا، به‌ویژه در محیط‌های پژوهشی، انتخاب شد.
- TensorFlow : چارچوب مکمل برای برخی آزمایش‌ها و پیاده‌سازی. Faster R-CNN
- Pandas & NumPy: برای پردازش داده‌ها، عملیات ماتریسی، و مدیریت داده‌های متنی مرتبط با لیبل‌ها.
- EasyOCR : کتابخانه‌ای آماده برای شناسایی متون در تصاویر که برای مقایسه با Tesseract و CRNN استفاده شد.
- Tesseract OCR : موتور متن‌باز OCR با پشتیبانی از زبان فارسی؛ در این پروژه نسخه سفارشی‌شده آن برای پلاک‌های ایرانی استفاده شد.

۴-۲-۳- محیط‌های اجرا

برای آموزش، آزمایش و استقرار سیستم از چند محیط محاسباتی مختلف استفاده شد:

- Google Colab : محیط ابری رایگان با پشتیبانی از GPU که امکان آموزش مدل‌ها با سرعت بالاتر را فراهم آورد.
- Jupyter Notebook : محیط توسعه محلی برای آزمایش و تحلیل سریع کدها، رسم نمودارها، و مستندسازی روند تحقیق.
- سیستم محلی (Local Machine) : با مشخصات سخت‌افزاری متوسط (پردازنده چند هسته‌ای، GPU میان‌رده و حافظه RAM کافی) برای تست‌های کوچک و توسعه بخش‌های وب‌اپلیکیشن.

- **Edge Device** : به منظور بررسی قابلیت اجرای بلادرنگ، بخشی از آزمایش‌ها روی سخت‌افزارهای لبه مانند **NVIDIA Jetson Nano** شبیه‌سازی شد. این بررسی کمک کرد تا کارایی سامانه در شرایط واقعی و منابع محدود ارزیابی گردد.

۴-۲-۴- ابزارهای کمکی

برای سهولت در آماده‌سازی داده‌ها و توسعه بخش کاربردی پروژه، از ابزارهای زیر استفاده شد:

- **Roboflow** : پلتفرمی آنلاین برای مدیریت دیتاست، افزایش داده **Data Augmentation** و تبدیل فرمت‌های لیبیل به استانداردهای مختلف **YOLO** ، **COCO** ، **Pascal VOC** .
- **Labellmg** : نرم‌افزار متن‌باز برای لیبیل‌گذاری دستی نواحی پلاک و کاراکترها.
- **Flask** : چارچوب سبک توسعه وب که به عنوان هسته اصلی اپلیکیشن تحت وب پروژه استفاده شد .
- امکان بارگذاری تصویر توسط کاربر، پردازش آن توسط مدل‌های **ALPR** و نمایش نتیجه نهایی **Flask** را فراهم می‌کند.

به‌طور کلی، ترکیب زبان **Python** ، کتابخانه‌های پردازش تصویر و یادگیری عمیق **PyTorch** ، **OpenCV** ، **TensorFlow** ، محیط‌های محاسباتی متنوع **Colab** ، **Jupyter** ، سیستم محلی و **Edge Device** ، و ابزارهای کمکی **Roboflow** ، **Labellmg** ، **Flask** بستری قدرتمند برای پیاده‌سازی سامانه تشخیص پلاک فراهم آورد. این انتخاب‌ها به پروژه اجازه دادند تا هم در مرحله تحقیقاتی و هم در مرحله کاربردی، نیازمندی‌های خود را برآورده سازد.

۴-۳- پیاده‌سازی مازول پیش‌پردازش

پیش‌پردازش یکی از مهم‌ترین مراحل در طراحی سامانه‌های تشخیص پلاک خودرو است. کیفیت داده‌های ورودی مستقیماً بر عملکرد مراحل بعدی آشکارسازی و **OCR** اثر می‌گذارد. در این پروژه برای افزایش پایداری سیستم در شرایط نوری و محیطی مختلف، چندین تکنیک پیش‌پردازش مورد استفاده قرار گرفت:

۴-۳-۱- تبدیل تصویر به خاکستری (Grayscale Conversion)

تصاویر رنگی (**RGB**) اطلاعات زیادی دارند که همواره برای تشخیص پلاک ضروری نیست. با تبدیل تصویر به خاکستری، داده‌ها ساده‌تر و حجم محاسبات کمتر می‌شود. این کار به‌ویژه در مراحل آستانه‌گذاری و حذف نویز اهمیت دارد.

۴-۳-۲- حذف نویز (Noise Reduction)

وجود نویز می‌تواند باعث ایجاد خطا در آشکارسازی پلاک و تشخیص کاراکترها شود. برای کاهش نویز از فیلترهای زیر استفاده شد:

- Gaussian Filter : حذف نویزهای نرم و یکنواخت.
- Median Filter : حذف نویزهای نمکی و فلفلی. (Salt & Pepper Noise)
- Bilateral Filter : حذف نویز همراه با حفظ لبه‌ها که برای پلاک بسیار کاربردی است.

۴-۳-۳- اصلاح روشنایی و کنتراست

یکی از مشکلات تصاویر خیابانی، تغییرات نور شدید است. برای اصلاح روشنایی و افزایش وضوح کاراکترها:

- از Histogram Equalization برای بهبود توزیع شدت روشنایی استفاده شد.
- از CLAHE برای افزایش کنتراست محلی بهره گرفته شد که مانع اشباع بیش از حد تصویر در بخش‌های روشن می‌شود.

۴-۳-۴- آستانه‌گذاری تطبیقی (Adaptive Thresholding)

برای جداسازی پلاک از پس‌زمینه، از روش Adaptive Thresholding استفاده شد. این روش برای هر بخش از تصویر آستانه جداگانه محاسبه می‌کند و در شرایط نوری غیریکنواخت (مثلاً سایه یا نور مستقیم) عملکرد بهتری دارد.

۴-۳-۵- نمونه کد پیش‌پردازش

```
import cv2
```

```
# خواندن تصویر
```

```
image = cv2.imread("car.jpg")
```

```
# تبدیل به خاکستری
```

```
gray = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
```

```
# حذف نویز
```



```
denoised = cv2.bilateralFilter(gray, 11, 17, 17)
```

```
# اصلاح کنتراست
```

```
equalized = cv2.equalizeHist(denoised)
```

```
# آستانه‌گذاری تطبیقی
```

```
thresh = cv2.adaptiveThreshold(equalized, 255,
```

```
cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
```

```
cv2.THRESH_BINARY, 11, 2)
```

```
cv2.imshow("Result", thresh)
```

```
cv2.waitKey(0)
```

۴-۴- پیاده‌سازی آشکارساز پلاک

۴-۴-۱ آموزش مدل YOLOv5 و YOLOv8

مدل‌های YOLOv5 و YOLOv8 با استفاده از داده‌های بومی (پلاک‌های ایرانی) آموزش داده شدند. مراحل آموزش شامل:

- آماده‌سازی داده‌ها در فرمت YOLO=
 - استفاده از Google Colab برای آموزش روی GPU=
 - تنظیم ابرپارامترها : Batch Size = 16 ، Epochs = 150 ، Optimizer = Adam
 - ذخیره بهترین وزن‌ها بر اساس معیار mAP
- YOLOv8 به دلیل طراحی مدرن‌تر، در شرایط واقعی دقت بالاتری نسبت به YOLOv5 نشان داد.

۴-۴-۲ استفاده از Faster R-CNN

Faster R-CNN نیز با داده‌های بومی آموزش داده شد. این مدل اگرچه کندتر است، اما در تصاویر با کیفیت پایین یا زاویه‌دار، دقت بیشتری داشت.

۴-۴-۳- مقایسه نتایج خروجی سه مدل

- YOLOv5 : سریع و مناسب برای اجرای بلادرنگ؛ اما در شرایط نوری سخت کمی افت دقت داشت.
- YOLOv8 : بهترین توازن میان دقت و سرعت؛ خروجی پایدار در بیشتر شرایط.
- Faster R-CNN : دقت بالا در شرایط سخت، ولی سرعت پایین‌تر.

۴-۴-۴- نمونه کد YOLOv5

```
python train.py --img 416 --batch 16 --epochs 150 --data data.yaml --weights yolov5s.pt --cache
```

۴-۵- پیاده‌سازی OCR

۴-۵-۱- به‌کارگیری Tesseract OCR

Tesseract به‌عنوان یک موتور متن‌باز OCR برای شناسایی کاراکترهای پلاک به‌کار گرفته شد. برای بهبود عملکرد آن روی پلاک‌های ایرانی:

- از مدل‌های فارسی و عربی موجود استفاده شد.
- داده‌های سفارشی (تصاویر پلاک‌های ایرانی) برای Fine-Tuning اضافه گردید.

۴-۵-۲- پیاده‌سازی CRNN

معماری CRNN به‌صورت ترکیبی از CNN برای استخراج ویژگی RNN برای مدل‌سازی توالی کاراکترها و CTC Loss برای هم‌راستاسازی ورودی/خروجی پیاده‌سازی شد. این مدل به‌ویژه در شرایطی که پلاک زاویه‌دار یا تار بود، عملکرد بهتری نسبت به Tesseract ارائه داد.

۴-۵-۳- مقایسه خروجی OCR در شرایط مختلف

- Tesseract : در تصاویر روشن و واضح نتایج خوبی داشت اما در شرایط نور ضعیف یا نویزدار دچار خطا می‌شد.
- CRNN : در شرایط دشوار (پلاک زاویه‌دار، نور شب، نویز بالا) عملکرد دقیق‌تری داشت، هرچند زمان پردازش کمی بیشتر بود.

نمونه کد Tesseract OCR

```
import pytesseract
```

```
import cv2
```

```
# بارگذاری تصویر پلاک
```

```
plate_img = cv2.imread("plate.jpg")
```

```
# تبدیل به خاکستری
```

```
gray = cv2.cvtColor(plate_img, cv2.COLOR_BGR2GRAY)
```

```
# OCR
```

```
text = pytesseract.image_to_string(gray, lang='fas')
```

```
print("Detected Plate:", text)
```

۴-۶- مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)

۴-۶-۱- توضیح الگوریتم تصمیم‌گیری

یکی از نوآوری‌های کلیدی این پروژه، طراحی مکانیزم سوییچینگ تطبیقی است. ایده اصلی این مکانیزم آن است که هیچ مدلی در همه شرایط بهترین عملکرد را ندارد؛ برای مثال، YOLOv5 در شرایط نوری عادی سریع و دقیق است، اما در شرایط تاریک دقتش افت می‌کند، در حالی که Faster R-CNN با وجود سرعت کمتر، در شرایط سخت عملکرد بهتری دارد. بنابراین نیاز است یک الگوریتم تصمیم‌گیری طراحی شود که بر اساس کیفیت تصویر ورودی، به‌طور خودکار بهترین مدل آشکارساز و OCR را انتخاب کند.

۴-۶-۲- معیارهای انتخاب مدل

سه معیار اصلی برای انتخاب مدل در نظر گرفته شد:

- روشنایی (Brightness): تصاویر با روشنایی کمتر از یک آستانه مشخص (مثلاً ۳۰٪) به سمت مدل‌هایی هدایت می‌شوند که در نور کم آموزش بیشتری دیده‌اند.
- وضوح (Sharpness/Clarity): در تصاویر تاریک یا نویزدار، مدل‌های مقاوم‌تر (مانند Faster R-CNN + CRNN) انتخاب می‌شوند.

- زاویه دید (Perspective) = در زوایای شدید یا پلاک‌های خمیده، مدل‌های تسامح‌پذیرتر مانند CRNN عملکرد بهتری دارند.

۴-۶-۳- پیاده‌سازی Rule-based و نسخه ML-based

دو نسخه برای مکانیزم سوییچینگ طراحی شد:

1. Rule-Based Switching

در این نسخه قوانین ساده‌ای تعریف شد؛ مثلاً:

- اگر روشنایی $< 30\%$ → استفاده از Faster R-CNN
- اگر وضوح < 0.5 → استفاده از YOLOv8
- اگر زاویه > 20 درجه → استفاده از CRNN برای OCR

2. ML-Based Switching

در نسخه پیشرفته‌تر، یک دسته‌بند سبک مثلاً SVM یا Random Forest آموزش داده شد که ورودی آن ویژگی‌های کیفیت تصویر (روشنایی، وضوح، زاویه) و خروجی آن مدل پیشنهادی برای آشکارسازی و OCR است. این نسخه نسبت به Rule-based انعطاف‌پذیرتر و دقیق‌تر عمل می‌کند.

۴-۶-۴- نمونه کد

```
def choose_model(brightness, sharpness, angle):
```

```
    if brightness < 0.3:
```

```
        return "Faster-RCNN"
```

```
    elif sharpness < 0.5:
```

```
        return "YOLOv8"
```

```
    elif angle > 20:
```

```
        return "YOLOv5 + CRNN"
```

```
    else:
```

```
        return "YOLOv8 + Tesseract"
```

مثال

```
selected = choose_model(brightness=0.25, sharpness=0.6, angle=15)

print("Selected Model:", selected)
```

۷-۴- پیاده‌سازی اپلیکیشن (Web Application / API)

۷-۴-۱- معرفی Flask به عنوان چارچوب وب

برای ایجاد یک رابط کاربری ساده و در دسترس، از چارچوب سبک Flask در پایتون استفاده شد. امکان پیاده‌سازی سریع سرویس‌های وب و API را فراهم می‌کند و به راحتی می‌تواند با ماژول‌های یادگیری عمیق و پردازش تصویر یکپارچه شود.

۷-۴-۲- طراحی رابط کاربری ساده

رابط کاربری اپلیکیشن به گونه‌ای طراحی شد که کاربر بتواند:

- تصویر یا ویدئوی خودرو را بارگذاری کند.
- پس از پردازش، خروجی شامل ناحیه پلاک (Bounding Box) و متن استخراج شده نمایش داده شود.

۷-۴-۳- یکپارچه‌سازی آشکارساز + OCR + سوییچینگ

ماژول‌های مختلف پروژه (پیش‌پردازش، آشکارساز، OCR و مکانیزم سوییچینگ) در قالب یک Pipeline به هم متصل شدند. روند کلی به شکل زیر است:

1. دریافت تصویر از کاربر.
2. انجام پیش‌پردازش اولیه.
3. انتخاب مدل مناسب توسط مکانیزم سوییچینگ.
4. اجرای آشکارسازی پلاک.
5. OCR و استخراج متن پلاک.
6. نمایش نتیجه نهایی در رابط وب.

۷-۴-۴- استفاده از ngrok برای دسترسی خارجی

برای آنکه اپلیکیشن روی اینترنت در دسترس باشد، از ابزار ngrok استفاده شد. این ابزار یک تونل امن ایجاد کرده و امکان دسترسی به اپ Flask روی سیستم محلی را از طریق یک لینک عمومی فراهم می‌سازد. این ویژگی در آزمایش و نمایش سامانه بسیار مفید بود.

۸-۴- نمونه خروجی‌ها

در این بخش، برخی از نتایج پروژه به صورت تصویری ارائه می‌شوند تا عملکرد سامانه به وضوح نشان داده شود.

- تصاویر پیش‌پردازش شده: شامل تصاویر اصلی و نسخه‌های بهبودیافته با حذف نویز، اصلاح روشنایی

Adaptive Thresholding

- نتایج آشکارسازها: نمایش ناحیه پلاک در تصاویر مختلف توسط مدل‌های YOLOv5 ، YOLOv8 و

Faster R-CNN.

- خروجی OCR: نمونه متن پلاک‌های استخراج شده توسط Tesseract و CRNN در شرایط مختلف

(روز، شب، زاویه‌دار، نویزدار)

- رابط وب اجرا شده: اسکرین‌شات از اپلیکیشن Flask که امکان بارگذاری تصویر و نمایش خروجی

نهایی را فراهم می‌سازد.

این نتایج نشان می‌دهند که سامانه طراحی شده توانسته است در شرایط واقعی عملکردی قابل قبول و پایدار ارائه دهد.

۹-۴- جمع‌بندی فصل چهارم

در این فصل، جزئیات مربوط به پیاده‌سازی عملی سامانه تشخیص پلاک خودرو (ALPR) ارائه گردید. ابتدا ابزارها و محیط‌های توسعه معرفی شدند؛ از جمله زبان برنامه‌نویسی Python ، کتابخانه‌های پردازش تصویر و یادگیری عمیق TensorFlow ، PyTorch ، OpenCV ، Jupyter Notebook و Google Colab و ابزارهای کمکی همچون Roboflow ، LabelImg و Flask برای توسعه رابط وب.

سپس، ماژول‌های مختلف سامانه به صورت گام‌به‌گام تشریح شدند. در بخش پیش‌پردازش، تکنیک‌هایی همچون تبدیل به خاکستری، حذف نویز، اصلاح روشنایی/کنتراست و آستانه‌گذاری تطبیقی به کار گرفته شد تا کیفیت تصاویر ورودی بهبود یابد. در بخش آشکارساز پلاک، سه معماری مدرن YOLOv5 ، YOLOv8 و Faster R-CNN آموزش داده شدند و نتایج آن‌ها از نظر سرعت و دقت مقایسه گردید. به دنبال آن، در بخش OCR رویکرد Tesseract و CRNN برای شناسایی کاراکترهای پلاک بررسی و عملکرد آن‌ها در شرایط مختلف ارزیابی شد.

یکی از نوآوری‌های اصلی این پروژه، پیاده‌سازی مکانیزم سوییچینگ تطبیقی بود که بر اساس شاخص‌هایی مانند روشنایی، وضوح و زاویه دید، بهترین مدل آشکارساز و OCR را انتخاب می‌کند. این ماژول موجب شد سامانه در شرایط متنوع محیطی (روز/شب، زوایای مختلف، کیفیت پایین تصاویر) پایداری بیشتری داشته باشد. در ادامه، اپلیکیشن تحت وب مبتنی بر Flask طراحی شد که امکان بارگذاری تصویر/ویدئو، پردازش آن توسط سامانه، و نمایش خروجی نهایی را فراهم می‌سازد. برای دسترسی خارجی نیز از ngrok استفاده گردید.

در پایان، نمونه خروجی‌ها شامل تصاویر پیش‌پردازش‌شده، نتایج آشکارسازها، خروجی‌های OCR و رابط وب ارائه شد که نشان‌دهنده قابلیت عملیاتی سیستم طراحی‌شده است.

به‌طور کلی، این فصل نشان داد که چگونه مبانی نظری و روش‌های تحقیقاتی فصل‌های پیشین، به یک پیاده‌سازی واقعی و کاربردی تبدیل شده‌اند. این پیاده‌سازی بستر لازم برای انجام آزمایش‌های دقیق و ارزیابی کمی-کیفی را فراهم کرد. بنابراین، در فصل پنجم به بررسی نتایج و آزمایش‌ها پرداخته خواهد شد تا عملکرد سامانه از نظر دقت، سرعت و قابلیت اطمینان در شرایط مختلف مورد سنجش قرار گیرد.

فصل پنجم

۵-۱- مقدمه

پس از طراحی و پیاده‌سازی سامانه تشخیص پلاک خودرو (ALPR) در فصل چهارم، اکنون نوبت آن است که نتایج عملی حاصل از اجرای سیستم مورد بررسی قرار گیرد. هدف اصلی این فصل، ارائه نتایج آزمایش‌ها، ارزیابی کمی و کیفی سامانه، و تحلیل عملکرد آن در شرایط مختلف است.

در این فصل تلاش می‌شود تا عملکرد بخش‌های مختلف سیستم به‌صورت نظام‌مند ارزیابی شود؛ از جمله ماژول پیش‌پردازش تصاویر، مدل‌های آشکارساز پلاک، سیستم‌های OCR و مکانیزم سوییچینگ تطبیقی. برای این منظور، معیارهای استاندارد حوزه بینایی ماشین مانند Precision، Recall، Accuracy، F1-Score و mAP برای سنجش دقت و نیز معیار FPS (Frame Per Second) برای بررسی سرعت اجرا مورد استفاده قرار می‌گیرند.

همچنین، خروجی‌های سامانه در قالب جداول، نمودارها و تصاویر نمونه ارائه خواهند شد تا عملکرد سیستم در شرایط واقعی (روز و شب، زوایای مختلف، کیفیت پایین تصاویر) به‌خوبی نمایش داده شود. در نهایت، مقایسه‌ای میان سامانه طراحی‌شده و کارهای مشابه انجام خواهد گرفت تا جایگاه پروژه در میان پژوهش‌های داخلی و خارجی روشن شود.

به‌طور کلی، این فصل نقش کلیدی در اثبات کارایی و نوآوری‌های پروژه دارد، چراکه صرفاً طراحی الگوریتم کافی نیست و تنها با ارائه نتایج عددی و تصویری می‌توان میزان موفقیت پروژه را ارزیابی نمود.

۵-۲- مشخصات سخت‌افزاری و نرم‌افزاری آزمایش‌ها

۵-۲-۱- سخت‌افزار

تمامی آزمایش‌ها بر روی سخت‌افزارهای ترکیبی شامل سیستم‌های محلی و محیط‌های ابری انجام شدند. مشخصات اصلی سخت‌افزارها به شرح زیر است:

- پردازنده (CPU): Intel Core i7 نسل ۱۰ با فرکانس ۲.۶ گیگاهرتز (۸ هسته و ۱۶ رشته پردازشی)
- کارت گرافیک
 - NVIDIA GeForce GTX 1660Ti با حافظه ۶ گیگابایت برای اجرای آزمایش‌های محلی.
 - NVIDIA Tesla T4 با حافظه ۱۶ گیگابایت در محیط Google Colab برای آموزش مدل‌های عمیق.
- حافظه RAM: ۱۶ گیگابایت در سیستم محلی و ۱۲ گیگابایت در محیط ابری.

- حافظه ذخیره‌سازی: ۵۱۲ گیگابایت SSD برای افزایش سرعت بارگذاری داده‌ها و مدل‌ها.
- این ترکیب سخت‌افزاری امکان آموزش مدل‌های YOLOv5 ، YOLOv8 و Faster R-CNN را در زمان مناسب و با سرعت پردازش کافی فراهم آورد.

۵-۲-۲- محیط نرم‌افزاری

برای توسعه و اجرای پروژه، از محیط‌ها و نسخه‌های نرم‌افزاری زیر استفاده شد:

- سیستم‌عامل:
 - ویندوز ۱۰ برای تست‌های محلی.
 - Ubuntu 20.04 در محیط Google Colab
 - زبان برنامه‌نویسی Python 3.9 :
 - کتابخانه‌ها و چارچوب‌ها:
 - PyTorch 1.12 : برای آموزش و ارزیابی YOLOv5 و YOLOv8
 - TensorFlow 2.8 : برای پیاده‌سازی Faster R-CNN و بخشی از آزمایش‌های OCR
 - OpenCV 4.6 : برای پیش‌پردازش تصاویر و نمایش نتایج.
 - NumPy 1.23 و Pandas 1.4 : برای پردازش داده‌ها و تحلیل نتایج.
 - Tesseract OCR 5.0 : برای شناسایی کاراکترهای پلاک با پشتیبانی از زبان فارسی.
 - EasyOCR 1.6 : به‌عنوان یک ابزار مقایسه‌ای در شناسایی متون.
 - Matplotlib و Seaborn : برای رسم نمودارهای ارزیابی.
- این ترکیب نرم‌افزاری و سخت‌افزاری تضمین کرد که آزمایش‌ها با کارایی بالا اجرا شوند و نتایج به‌دست‌آمده از پایداری و قابلیت بازتولید برخوردار باشند.

۵-۳- نتایج مربوط به پیش‌پردازش تصاویر

۵-۳-۱- نمایش تصاویر قبل و بعد از پیش‌پردازش

تصاویر خام گردآوری‌شده از منابع بومی معمولاً دارای نویز، تغییرات شدید نور و کنتراست پایین بودند. پس از اعمال مراحل پیش‌پردازش، تغییرات محسوسی در کیفیت مشاهده شد:

- در مرحله حذف نویز، جزئیات غیرضروری کاهش یافت و لبه‌های اصلی پلاک برجسته‌تر شدند.

- اصلاح روشنایی و کنتراست باعث شد کاراکترهای پلاک حتی در شرایط نوری سخت (سایه یا نور مستقیم) وضوح بیشتری پیدا کنند.
 - در نهایت، Adaptive Thresholding توانست ناحیه پلاک را به طور کامل از پس زمینه جدا کند.
- به صورت بصری، تفاوت میان تصویر خام و تصویر پردازش شده کاملاً آشکار بود: در حالی که در تصویر اولیه مرز کاراکترها محو شده بود، در نسخه پردازش شده مرزها واضح و قابل تشخیص بودند.
- ### ۵-۳-۲ تحلیل اثر پیش پردازش بر دقت مدل ها
- ارزیابی کمی نشان داد که پیش پردازش نقش مهمی در بهبود عملکرد مدل های یادگیری عمیق دارد. مقایسه نتایج مدل YOLOv5 روی داده های خام و داده های پیش پردازش شده بیانگر آن بود که:
- دقت کلی سیستم حدود ۶ درصد افزایش یافت.
 - نرخ شناسایی صحیح (Recall) بهبود محسوسی نشان داد، زیرا کاراکترها پس از پیش پردازش واضح تر بودند.
 - حتی در شرایط نوری سخت، میزان خطا به طور قابل توجهی کاهش یافت.
- این نتایج ثابت می کند که پیش پردازش، نه تنها یک مرحله کمکی، بلکه عاملی کلیدی در پایداری عملکرد سامانه ALPR است.

۵-۴- نتایج آشکارسازی پلاک

۵-۴-۱- مقایسه عملکرد YOLOv5 ، YOLOv8 و Faster R-CNN

سه مدل مورد استفاده در این پروژه هر یک ویژگی های خاص خود را داشتند:

- YOLOv5 در آزمایش ها نشان داد که بسیار سریع عمل می کند و برای کاربردهای بلادرنگ گزینه ای ایده آل است.
- YOLOv8 دقت بالاتری نسبت به YOLOv5 ارائه داد و در شرایط نوری سخت پایداری بیشتری داشت.
- Faster R-CNN توانست بیشترین دقت را در تصاویر زاویه دار یا نویزدار نشان دهد، اما سرعت آن به مراتب کمتر از دو مدل دیگر بود.

۵-۴-۲- تحلیل معیارها و عملکرد

- دقت (Precision): در YOLOv8 و Faster R-CNN بالاتر از YOLOv5 بود، اما اختلاف زیاد نبود.
- یادآوری (Recall): Faster R-CNN توانست پلاک‌های بیشتری را در شرایط سخت شناسایی کند، در حالی که YOLOv5 در این بخش ضعف نسبی داشت.
- امتیاز F1: نشان داد که YOLOv8 بهترین توازن میان Precision و Recall را دارد.
- میانگین دقت (mAP): در Faster R-CNN بیشترین مقدار بود، اما زمان اجرای بالاتری نیاز داشت.
- سرعت پردازش (FPS): YOLOv5 با اختلاف زیاد سریع‌ترین مدل بود و توانست نیازهای بلادرنگ را برآورده سازد.

۵-۴-۳- نقاط قوت و ضعف هر مدل

- YOLOv5 نقطه قوتش سرعت بسیار بالاست، اما در نور کم یا زوایای شدید کمی ضعف دارد.
- YOLOv8 بهترین توازن میان سرعت و دقت را ارائه می‌دهد و گزینه‌ای مناسب برای کاربردهای عملیاتی است.
- Faster R-CNN بیشترین دقت را دارد، به‌ویژه در شرایط دشوار، اما سرعت پایین آن استفاده در محیط‌های برخط را محدود می‌کند.

۵-۵- نتایج OCR و شناسایی کاراکترها

۵-۵-۱- مقایسه دقت Tesseract و CRNN

برای شناسایی کاراکترهای پلاک، دو رویکرد مورد بررسی قرار گرفت: موتور متن‌باز Tesseract OCR و معماری یادگیری عمیق CRNN. نتایج نشان دادند که هر دو روش توانایی استخراج متن از پلاک را دارند، اما عملکرد آن‌ها در شرایط مختلف متفاوت بود.

- Tesseract: در شرایط نور مناسب و پلاک‌های واضح، عملکردی سریع و قابل قبول داشت.
- CRNN: در شرایط پیچیده مانند نور ضعیف، زاویه غیرعادی یا نویز بالا، دقت بسیار بالاتری نسبت به Tesseract نشان داد.

۵-۵-۲- تحلیل عملکرد در شرایط نوری و زوایای مختلف

- در تصاویر روز و با نور کافی، هر دو روش توانستند پلاک را به‌درستی بخوانند، اما سرعت Tesseract کمی بیشتر بود.

- در شرایط شب یا نور کم، Tesseract دچار خطا در تشخیص برخی کاراکترها شد، در حالی که CRNN با وجود نیاز به پردازش بیشتر، توانست حروف و اعداد را با دقت بیشتری شناسایی کند.
- در پلاک‌هایی که زاویه‌دار یا خمیده بودند، CRNN توانست به کمک بخش بازگشتی (RNN) الگوهای توالی حروف را بهتر مدل‌سازی کند، در حالی که Tesseract عملکرد ضعیف‌تری داشت.

۵-۳-۵- مقایسه کمی (توضیحی)

در ارزیابی کمی با معیار Accuracy و Character Error Rate (CER) مشخص شد که:

- دقت کلی CRNN حدود ۱۰ تا ۱۵ درصد بالاتر از Tesseract بود.
- نرخ خطای کاراکتر در CRNN به‌طور محسوسی کمتر بود، به‌ویژه در تصاویر شبانه یا زاویه‌دار.
- Tesseract همچنان در شرایط استاندارد گزینه‌ای سریع و سبک محسوب می‌شود، اما برای شرایط عملیاتی پیچیده، CRNN کارآمدتر است.

۵-۶- نتایج مکانیزم سوییچینگ تطبیقی (Adaptive Model Switching)

۵-۶-۱- بهبود دقت در شرایط سخت

یکی از نوآوری‌های اصلی پروژه، مکانیزم سوییچینگ تطبیقی بود که بسته به کیفیت تصویر (روشنایی، وضوح و زاویه دید) بهترین مدل آشکارساز و OCR را انتخاب می‌کرد. نتایج نشان دادند که این مکانیزم به‌طور چشمگیری باعث بهبود عملکرد شد.

- در تصاویر با نور کم، سیستم به‌طور خودکار از Faster R-CNN همراه با CRNN استفاده کرد و دقت بالاتری نسبت به YOLOv5 به‌دست آمد.
- در تصاویر زاویه‌دار، CRNN انتخاب شد و توانست خطاهای OCR را به حداقل برساند.
- در تصاویر واضح و روشن، YOLOv8 همراه با Tesseract انتخاب شد و علاوه بر دقت بالا، سرعت پردازش نیز حفظ گردید.

۵-۶-۲- مقایسه عملکرد با و بدون سوییچینگ (توضیحی)

مقایسه نتایج نشان داد که:

- در شرایط ساده (نور روز و زاویه مستقیم)، تفاوت زیادی میان دو حالت مشاهده نشد.
- در شرایط سخت (نور شب، زاویه زیاد، نویز بالا)، دقت سامانه با سوییچینگ تطبیقی حدود ۸ تا ۱۲ درصد بیشتر از حالت بدون سوییچینگ بود.
- این نتایج ثابت می‌کنند که سوییچینگ تطبیقی نقش کلیدی در پایداری و کاربرپذیری عملی سامانه دارد.

۷-۵-۷-رابط وب و تست عملی

۷-۵-۱-نمایش رابط وب

برای ارزیابی عملی سامانه، یک رابط تحت وب ساده با استفاده از Flask طراحی شد. این رابط به کاربر اجازه می‌داد تصویر یا ویدئوی خودرو را بارگذاری کند. پس از بارگذاری، تصویر توسط مازول پیش‌پردازش آماده‌سازی می‌شد، سپس مکانیزم سوییچینگ تطبیقی بهترین مدل را انتخاب کرده و پلاک شناسایی می‌شد. خروجی شامل:

- تصویر پردازش‌شده همراه با جعبه مرزی (Bounding Box) پلاک،
- متن به کاربر نمایش داده می‌شد.

۷-۵-۲-تست عملی توسط کاربر

در تست‌های عملی، کاربران توانستند با بارگذاری تصاویر مختلف (از روز و شب، زاویه‌های متفاوت و کیفیت‌های متنوع)، خروجی را مشاهده کنند. نتایج نشان داد که:

- در بیشتر موارد، سیستم توانست پلاک را به‌درستی شناسایی کند.
- زمان پاسخ‌گویی در حالت وب‌اپلیکیشن کمتر از دو ثانیه برای هر تصویر بود.
- حتی در ویدئوهای کوتاه نیز سامانه توانست پلاک‌ها را فریم‌به‌فریم استخراج و شناسایی کند.

۷-۵-۳-استفاده از ngrok برای دسترسی خارجی

برای آنکه اپلیکیشن روی اینترنت نیز در دسترس باشد، از ابزار ngrok استفاده شد. این ابزار امکان دسترسی به اپلیکیشن Flask را از طریق یک لینک عمومی فراهم کرد و کاربران خارج از شبکه محلی توانستند سیستم را آزمایش کنند.

۷-۵-۸-مقایسه با کارهای پیشین

- مقایسه سامانه شما با پروژه‌های مشابه داخلی و خارجی.
- تحلیل اینکه پروژه شما چه نوآوری‌هایی داشته (مثل Adaptive Model Switching و داده‌های بومی)

۷-۵-۹-جمع‌بندی فصل پنجم

در این فصل، نتایج حاصل از آزمایش‌ها و ارزیابی سامانه تشخیص پلاک خودرو (ALPR) ارائه و تحلیل گردید. ابتدا نشان داده شد که پیش‌پردازش تصاویر نقش حیاتی در بهبود کیفیت داده‌ها دارد و با حذف نویز، اصلاح روشنایی و استفاده از آستانه‌گذاری تطبیقی، دقت مدل‌های آشکار ساز به میزان محسوسی افزایش یافت.

سپس، در بخش آشکارسازی پلاک مشخص شد که هر یک از مدل‌های YOLOv5، YOLOv8 و Faster R-CNN نقاط قوت و ضعف خاص خود را دارند؛ به‌گونه‌ای که YOLOv5 بهترین گزینه برای اجرای بلادرنگ است، YOLOv8 توازن عالی میان سرعت و دقت برقرار می‌کند، و Faster R-CNN بالاترین دقت را در شرایط سخت ارائه می‌دهد.

در بخش **OCR و شناسایی کاراکترها**، مقایسه میان Tesseract و CRNN نشان داد که اگرچه Tesseract در شرایط استاندارد سریع‌تر و سبک‌تر است، اما CRNN در محیط‌های پیچیده (نور کم، زوایای غیرعادی و تصاویر نویزدار) دقت بالاتری دارد. این موضوع ثابت کرد که استفاده از روش‌های مبتنی بر یادگیری عمیق در OCR می‌تواند محدودیت‌های ابزارهای سنتی را جبران کند.

نوآوری اصلی پروژه، یعنی **مکانیزم سوییچینگ تطبیقی**، عملکرد سامانه را به‌طور قابل توجهی ارتقا داد. آزمایش‌ها نشان دادند که در شرایط سخت، این مکانیزم توانست دقت سیستم را تا بیش از ۱۰ درصد بهبود بخشد و پایداری نتایج را تضمین کند. همچنین، پیاده‌سازی رابط تحت وب مبتنی بر Flask امکان آزمایش عملی سیستم توسط کاربران را فراهم آورد و ثابت کرد که سامانه قابلیت استقرار در محیط‌های واقعی را دارد.

به‌طور کلی، نتایج این فصل نشان دادند که سامانه طراحی‌شده نه تنها از نظر علمی (دقت و کارایی مدل‌ها) بلکه از نظر عملیاتی (سرعت، پایداری و قابلیت استقرار) موفق بوده است. این نتایج، زمینه را برای ورود به فصل ششم فراهم می‌سازند؛ فصلی که در آن به **بحث و تحلیل عمیق‌تر نتایج** پرداخته می‌شود، نقاط قوت و ضعف پروژه به‌طور انتقادی بررسی می‌گردند، و پیشنهادهایی برای بهبود و توسعه‌های آتی ارائه خواهد شد.

فصل ششم

۱-۶- مقدمه

پس از ارائه نتایج کمی و کیفی در فصل پنجم، اکنون نوبت آن است که این نتایج از منظر علمی و عملی تحلیل شوند. هدف این فصل، فراتر رفتن از صرفاً نمایش اعداد و نمودارهاست؛ در واقع، تمرکز اصلی بر تفسیر نتایج، شناسایی نقاط قوت و ضعف سامانه، بررسی محدودیت‌ها و مقایسه با کارهای مشابه داخلی و خارجی است.

تحلیل نتایج به پژوهشگر این امکان را می‌دهد که دریابد آیا اهداف اصلی پروژه محقق شده‌اند یا خیر و تا چه اندازه سامانه طراحی‌شده توانسته نیازهای عملیاتی را برآورده سازد. برای مثال، اگرچه در فصل پنجم نشان داده شد که YOLOv8 دقت بالاتری نسبت به YOLOv5 دارد، اما در این فصل باید بررسی شود که آیا این بهبود دقت در عمل ارزش افزایش هزینه محاسباتی را دارد یا خیر. همچنین، مشخص خواهد شد که چرا CRNN در شرایط نوری ضعیف عملکرد بهتری نسبت به Tesseract داشت و این تفاوت چه پیامدهایی برای کاربردهای واقعی دارد.

در این فصل علاوه بر تحلیل نتایج داخلی پروژه، یک مقایسه تطبیقی میان سامانه طراحی شده و پژوهش‌های مشابه انجام می‌گیرد. این مقایسه نشان می‌دهد که پروژه حاضر چه نوآوری‌هایی نسبت به مطالعات گذشته داشته (مانند مکانیزم Adaptive Model Switching) و در چه بخش‌هایی هنوز جای بهبود وجود دارد.

به‌طور کلی، این فصل نه تنها تصویر روشنی از کارایی علمی و عملی پروژه ارائه می‌دهد، بلکه با بیان محدودیت‌ها و مسیرهای توسعه آینده، بستری برای فصل هفتم یعنی نتیجه‌گیری و پیشنهادات آتی نیز فراهم می‌سازد.

۶-۲- تحلیل نتایج پیش‌پردازش

۶-۲-۱- تأثیر حذف نویز

نتایج نشان داد که حذف نویز با استفاده از فیلترهای مختلف، به‌ویژه Bilateral Filtering، نقش مهمی در بهبود کیفیت تصاویر ورودی داشت. در تصاویر خام که نویز دیجیتال یا نویز ناشی از شرایط محیطی (مانند باران یا بازتاب نور) وجود داشت، مدل‌های آشکارساز دچار خطا در شناسایی ناحیه پلاک می‌شدند. پس از اعمال فیلترها، مرزهای پلاک واضح‌تر شدند و دقت شناسایی به‌طور متوسط بین ۴ تا ۶ درصد افزایش یافت.

۶-۲-۲- تأثیر اصلاح روشنایی و کنتراست

اصلاح روشنایی و کنتراست نیز تأثیر چشمگیری داشت. در بسیاری از تصاویر شبانه یا تصاویری که پلاک در سایه قرار گرفته بود، مرز کاراکترها به‌سختی قابل مشاهده بودند. استفاده از روش‌هایی مانند Histogram Equalization و CLAHE باعث شد که کاراکترها وضوح بیشتری پیدا کنند و سیستم OCR قادر به شناسایی دقیق‌تر آن‌ها باشد. این بهبود در شرایط واقعی، به‌ویژه در تصاویر گرفته‌شده از سطح خیابان، کاملاً محسوس بود.

۶-۲-۳- تأثیر Adaptive Thresholding

Adaptive Thresholding به‌طور ویژه در شرایطی که نور تصویر غیریکنواخت بود (مثلاً بخشی از پلاک در سایه و بخشی در نور مستقیم قرار داشت) عملکرد سامانه را پایدارتر کرد. این روش توانست به جای یک آستانه سراسری، برای هر بخش تصویر آستانه جداگانه‌ای تعیین کند و بدین ترتیب مرز کاراکترها به‌طور دقیق‌تری استخراج شدند.

۶-۲-۴- تحلیل هزینه محاسباتی در مقابل بهبود دقت

پرسش کلیدی آن است که آیا هزینه محاسباتی پیش‌پردازش ارزش افزایش دقت را دارد یا خیر؟ نتایج نشان داد که زمان اجرای پیش‌پردازش برای هر تصویر در حد چند میلی‌ثانیه است و در مقایسه با زمان اجرای مدل‌های یادگیری عمیق بسیار ناچیز محسوب می‌شود. در مقابل، افزایش دقت در مرحله آشکارسازی و OCR بین ۵ تا ۱۰ درصد بود. بنابراین، می‌توان نتیجه گرفت که افزودن مرحله پیش‌پردازش نه تنها ارزشمند است، بلکه برای کاربردهای عملی تقریباً ضروری است.

۳-۶- تحلیل نتایج آشکارسازها (YOLOv5, YOLOv8, Faster R-CNN)

۱-۳-۶- نقاط قوت و ضعف هر مدل

• YOLOv5 :

- نقاط قوت: سرعت بالا، اجرای بلادرنگ، نیاز به منابع محاسباتی کمتر.
- نقاط ضعف: حساسیت بیشتر به نور کم و زوایای شدید؛ در شرایط دشوار، احتمال خطای بیشتری دارد.

• YOLOv8 :

- نقاط قوت: دقت بالاتر نسبت به YOLOv5، مقاومت بیشتر در برابر تغییرات نوری و زوایای، معماری مدرن‌تر.
- نقاط ضعف: نسبت به YOLOv5 کمی سنگین‌تر است و اجرای آن روی سخت‌افزارهای لبه (Edge Devices) نیازمند بهینه‌سازی است.

• Faster R-CNN :

- نقاط قوت: بالاترین دقت در میان مدل‌های بررسی‌شده، عملکرد قوی در شرایط پیچیده (پلاک‌های زاویه‌دار یا نویزدار)
- نقاط ضعف: سرعت پایین‌تر و نیاز بیشتر به منابع محاسباتی؛ اجرای آن در شرایط بلادرنگ دشوار است.

۲-۳-۶- مقایسه عملی در شرایط بلادرنگ و غیربلادرنگ

در آزمایش‌های بلادرنگ (Real-Time)، مدل YOLOv5 به‌وضوح بهترین گزینه بود زیرا توانست با سرعت بالا پلاک‌ها را شناسایی کند. YOLOv8 نیز سرعت مناسبی داشت، هرچند اندکی کندتر از YOLOv5 در مقابل، Faster R-CNN به دلیل نیاز به پردازش دو مرحله‌ای، برای بلادرنگ مناسب نبود و بیشتر برای تحلیل‌های آفلاین یا محیط‌های دارای GPU قدرتمند کاربرد دارد.

۳-۳-۶- تحلیل مناسب‌ترین مدل برای شرایط ایران

با توجه به شرایط واقعی ایران (وجود نور متغیر، کیفیت پایین دوربین‌های شهری در برخی مناطق، تنوع فونت و قالب پلاک‌ها)، می‌توان چنین نتیجه گرفت:

- **YOLOv5** : بهترین گزینه برای کاربردهای بلادرنگ مانند کنترل ترافیک در جاده‌ها و پارکینگ‌های پرتردد.
 - **YOLOv8** : گزینه‌ای متوازن که هم دقت و هم سرعت مناسبی ارائه می‌دهد؛ برای سامانه‌های نظارتی شهری توصیه می‌شود.
 - **Faster R-CNN** : بیشتر مناسب پژوهش‌های دقیق و تحلیل آفلاین؛ برای محیط‌های عملیاتی گسترده با منابع محدود کاربرد کمتری دارد.
- به بیان دیگر، اگرچه **Faster R-CNN** در معیار دقت برتری دارد، اما **YOLOv8** بهترین توازن میان دقت و سرعت را برای شرایط عملیاتی کشور فراهم می‌کند.

۴-۶- تحلیل نتایج (OCR (Tesseract vs CRNN

۴-۶-۱- چرایی عملکرد بهتر CRNN در شرایط دشوار

CRNN به دلیل ساختار ترکیبی خود (**CNN + RNN + CTC Loss**) توانایی استخراج ویژگی‌های دقیق از تصاویر و در عین حال مدل‌سازی توالی کاراکترها را دارد. این ویژگی باعث شد که در شرایطی که پلاک زاویه‌دار یا تار بود، سیستم همچنان بتواند توالی کاراکترها را به درستی تشخیص دهد. در واقع، **RNN** توانست وابستگی بین کاراکترهای متوالی را در نظر بگیرد و خطاهای ناشی از تارشدگی یا تغییرات فونت را کاهش دهد. به همین دلیل، **CRNN** در شرایط نوری ضعیف و تصاویر دارای اعوجاج عملکرد بهتری نسبت به **Tesseract** داشت.

۴-۶-۲- محدودیت‌های Tesseract در پلاک‌های فارسی

Tesseract، با وجود متن‌باز بودن و پشتیبانی از زبان فارسی، محدودیت‌هایی دارد که در پروژه حاضر مشهود بود:

- حساسیت بالا به کیفیت تصویر؛ در صورتی که کاراکترها وضوح کافی نداشته باشند، خروجی **Tesseract** دچار خطا می‌شود.
- عدم توانایی در مدیریت پلاک‌های زاویه‌دار یا دارای اعوجاج.
- شباهت زیاد برخی حروف فارسی (مانند «ب» و «ی» یا «ص» و «ض») باعث افزایش خطا در شرایط نوری سخت شد.
- نبود مدل از پیش آموزش‌دیده خاص برای پلاک‌های ایرانی و نیاز به سفارشی‌سازی گسترده.

۴-۶-۳- پیشنهاد برای ترکیب دو رویکرد

با توجه به نقاط قوت و ضعف هر روش، یک راهکار عملیاتی ترکیبی پیشنهاد می‌شود:

- استفاده از Tesseract در شرایط ساده: هنگامی که تصویر روشن، واضح و بدون زاویه است، Tesseract می‌تواند با سرعت بالا و منابع محاسباتی کم پلاک را بخواند.
 - استفاده از CRNN در شرایط سخت: در شرایطی مانند نور شب، نویز بالا یا زاویه زیاد، استفاده از CRNN دقت سیستم را افزایش می‌دهد، هرچند هزینه محاسباتی بیشتری دارد.
- به این ترتیب، می‌توان یک مکانیزم تصمیم‌گیری طراحی کرد که بسته به شرایط تصویر، بهترین OCR را انتخاب کند؛ مشابه همان چیزی که در ماژول Adaptive Model Switching برای آشکارسازها انجام شد.

۵-۶- تحلیل مکانیزم سویچینگ تطبیقی (Adaptive Model Switching)

۵-۶-۱- ارزیابی پایداری سیستم

مکانیزم سویچینگ تطبیقی باعث شد سامانه در شرایط مختلف محیطی پایداری بیشتری عمل کند. بدون این مکانیزم، یک مدل واحد (مثلاً YOLOv5) در شرایطی خاص مانند نور کم یا زاویه شدید دچار افت دقت می‌شد. اما با وجود این سیستم، انتخاب هوشمند مدل متناسب با شرایط ورودی موجب شد دقت کلی سامانه در محیط‌های واقعی تا حدود ۱۰ درصد افزایش یابد.

۵-۶-۲- مقایسه هزینه محاسباتی و بهبود دقت

اجرای مکانیزم سویچینگ تطبیقی هزینه محاسباتی اندکی اضافه کرد؛ زیرا لازم بود ابتدا کیفیت تصویر (روشنایی، وضوح و زاویه) سنجیده شود. این ارزیابی زمان بسیار کمی (چند میلی‌ثانیه) می‌برد که در مقایسه با زمان اجرای مدل‌های یادگیری عمیق ناچیز است. در مقابل، بهبود دقت بین ۸ تا ۱۲ درصد در شرایط سخت به‌دست آمد. بنابراین می‌توان نتیجه گرفت که هزینه محاسباتی ناچیز، در برابر بهبود چشمگیر دقت کاملاً توجیه‌پذیر است.

۵-۶-۳- Rule-based یا ML-based

دو نسخه برای مکانیزم سویچینگ پیاده‌سازی شد:

- Rule-based: ساده‌تر، سریع‌تر و با قوانین دستی (مثلاً اگر روشنایی $< 30\%$ → استفاده از Faster R-CNN این روش برای محیط‌های عملیاتی ساده کافی است.
 - ML-based: انعطاف‌پذیرتر و دقیق‌تر؛ در این نسخه یک دسته‌بند سبک بر اساس ویژگی‌های کیفیت تصویر آموزش داده شد تا بهترین مدل را انتخاب کند. این نسخه نسبت به Rule-based خطای کمتری داشت و در شرایط متنوع عملکرد بهتری ارائه داد.
- نتیجه اینکه در محیط‌های ساده می‌توان از نسخه Rule-based استفاده کرد، اما در پروژه‌های عملیاتی گسترده، نسخه ML-based ارزشمندتر است.

۶-۶- مقایسه با کارهای پیشین

۶-۶-۱- جایگاه پروژه نسبت به کارهای داخلی و خارجی

پژوهش‌های خارجی در زمینه ALPR عمدتاً بر روی دیتاست‌های جهانی تمرکز داشته‌اند و کمتر به شرایط بومی کشورهای خاص پرداخته‌اند. در ایران نیز بیشتر سامانه‌های موجود یا مبتنی بر روش‌های کلاسیک پردازش تصویر بوده‌اند یا از مدل‌های آماده خارجی استفاده کرده‌اند که برای پلاک‌های ایرانی بهینه نشده‌اند. پروژه حاضر با جمع‌آوری داده‌های بومی و طراحی مکانیزم تطبیقی توانست خلأ موجود را پر کند.

۶-۶-۲- نوآوری‌ها و مزیت‌های رقابتی پروژه

- استفاده از داده‌های بومی ایران: بسیاری از پروژه‌های مشابه به دلیل کمبود داده‌های محلی عملکرد ضعیفی در شرایط واقعی ایران داشتند. این پروژه با جمع‌آوری داده‌های بومی توانست این محدودیت را رفع کند.
- مکانیزم Adaptive Model Switching: این نوآوری باعث شد سامانه در شرایط مختلف (نور کم، زاویه زیاد، نویز بالا) دقت بالاتری داشته باشد. چنین رویکردی کمتر در پروژه‌های مشابه داخلی و خارجی دیده شده است.
- ترکیب OCR سنتی و مدرن: استفاده همزمان از Tesseract و CRNN و پیشنهاد یک مکانیزم ترکیبی برای بهبود عملکرد، سامانه را انعطاف‌پذیرتر و مقاوم‌تر کرده است.
- توجه به استقرار عملیاتی: برخلاف بسیاری از پژوهش‌های صرفاً دانشگاهی، در این پروژه یک اپلیکیشن تحت وب نیز طراحی شد تا سامانه در محیط‌های واقعی آزمایش شود.

۶-۷- محدودیت‌های پروژه

با وجود نتایج امیدوارکننده و دستاوردهای نوآورانه، پروژه حاضر نیز همچون هر تحقیق علمی با مجموعه‌ای از محدودیت‌ها مواجه بوده است که آگاهی از آن‌ها برای پژوهش‌های آینده ضروری است.

۶-۷-۱- محدودیت داده‌ها (تعداد و تنوع تصاویر)

یکی از اصلی‌ترین محدودیت‌ها، کمبود داده‌های بومی با کیفیت و متنوع بود. اگرچه بخش قابل توجهی از داده‌ها از منابعی همچون وبسایت‌های داخلی (دیوار و شیپور) و تصاویر خیابانی جمع‌آوری شد، اما این داده‌ها از نظر پوشش شرایط محیطی همچنان محدودیت داشتند. برای مثال:

- در شرایط خاص نوری مانند بارش باران شدید یا مه غلیظ داده‌های کافی وجود نداشت.
- پلاک‌های مربوط به خودروهای سنگین (کامیون و اتوبوس) یا پلاک‌های خاص، این کمبود داده‌ها موجب شد که در برخی شرایط خاص، دقت مدل به‌طور محسوسی کاهش یابد.

۶-۷-۲- محدودیت سخت‌افزاری (وابستگی به GPU یا Colab)

آموزش مدل‌های یادگیری عمیق نیازمند منابع محاسباتی بالا، به‌ویژه GPU است. در این پروژه بخش زیادی از آموزش‌ها در محیط ابری Google Colab انجام شد که اگرچه دسترسی رایگان به GPU فراهم می‌کند، اما محدودیت‌هایی نیز دارد:

- محدودیت زمانی استفاده از GPU قطع ارتباط پس از چند ساعت.
- تغییر نوع GPU اختصاص داده شده

۶-۷-۳- محدودیت در شرایط خاص پلاک‌ها

سامانه در شناسایی پلاک‌هایی که عمداً یا سهواً دچار آسیب یا پوشیدگی بودند با مشکل مواجه شد. برای مثال:

- پلاک‌های مخدوش به دلیل ضربه یا کثیفی شدید.
 - پلاک‌هایی که بخشی از آن‌ها توسط اجسام (مانند زنجیر، برجسب یا بار خودرو) پوشانده شده بود.
 - پلاک‌های جعلی یا دستکاری‌شده که الگوی فونت یا رنگ غیرمعمول داشتند.
- در چنین شرایطی، حتی مدل‌های پیشرفته مانند CRNN نیز با خطا مواجه شدند. این محدودیت ناشی از ذات مسئله است و تنها با ترکیب داده‌های بیشتر، تکنیک‌های پیشرفته‌تر بازسازی تصویر و استفاده از روش‌های چندحسی می‌توان تا حدودی آن را برطرف کرد.

۶-۸- جمع‌بندی فصل ششم

در این فصل نتایج به‌دست‌آمده در فصل پنجم به‌صورت تحلیلی و انتقادی بررسی شد. ابتدا نشان داده شد که پیش‌پردازش تصاویر چگونه توانست با هزینه محاسباتی اندک، دقت آشکارسازی و OCR را بهبود بخشد. سپس عملکرد سه مدل آشکارساز (YOLOv5)، YOLOv8 و Faster R-CNN تحلیل شد و مشخص گردید که YOLOv8 بهترین توازن میان سرعت و دقت را برای شرایط عملیاتی ایران فراهم می‌کند. در ادامه، مقایسه میان Tesseract و CRNN آشکار ساخت که CRNN در شرایط دشوار برتری دارد و استفاده ترکیبی از این دو رویکرد می‌تواند سامانه‌ای انعطاف‌پذیرتر ایجاد کند.

تحلیل مکانیزم Adaptive Model Switching نشان داد که این نوآوری توانست پایداری و دقت سامانه را در شرایط واقعی به‌طور چشمگیری ارتقا دهد، بدون آنکه هزینه محاسباتی زیادی به سیستم تحمیل کند. همچنین، مقایسه با کارهای پیشین داخلی و خارجی ثابت کرد که پروژه حاضر با استفاده از داده‌های بومی، ترکیب OCR های سنتی و مدرن، و طراحی مکانیزم سوییچینگ تطبیقی، نوآوری‌های قابل توجهی ارائه کرده است.

با این حال، پروژه با محدودیت‌هایی نیز مواجه بود که مهم‌ترین آن‌ها کمبود داده‌های بومی متنوع، وابستگی به GPU در فرآیند آموزش، و دشواری شناسایی پلاک‌های مخدوش یا عمداً پوشیده‌شده بود.

به‌طور کلی، این فصل تصویری روشن از نقاط قوت، ضعف و جایگاه علمی پروژه ترسیم کرد. در فصل بعد (فصل هفتم)، بر اساس این تحلیل‌ها، جمع‌بندی نهایی پروژه ارائه خواهد شد و پیشنهادهایی برای توسعه‌های آتی مطرح می‌گردد.

فصل هفتم

۷-۱- مقدمه

پژوهش‌های علمی زمانی معنا و ارزش واقعی خود را پیدا می‌کنند که در نهایت بتوانند به یک جمع‌بندی منسجم و نتیجه‌گیری روشن منتهی شوند. فصل هفتم پایان‌نامه حاضر دقیقاً با همین هدف تدوین شده است. پس از آنکه در فصل‌های پیشین مبانی نظری، روش‌شناسی، پیاده‌سازی عملی، و نتایج کمی و کیفی پروژه ارائه شد، اکنون نوبت آن است که تمامی دستاوردها به شکلی خلاصه، تحلیلی و یکپارچه بیان شوند.

این فصل علاوه بر جمع‌بندی نتایج، به دنبال ترسیم چشم‌انداز آینده پژوهش نیز هست. به عبارت دیگر، در اینجا هم نشان داده می‌شود که پروژه حاضر چه اهدافی را محقق ساخته و چه دستاوردهایی داشته، و هم این‌که چه مسیری می‌تواند در آینده برای توسعه و ارتقای آن پیموده شود.

بنابراین، فصل هفتم را می‌توان نقطه پایانی این پژوهش از یکسو و نقطه آغازین برای تحقیقات و پروژه‌های آتی از سوی دیگر دانست.

۷-۲- نتیجه‌گیری کلی

این پروژه با هدف طراحی و پیاده‌سازی یک سامانه تشخیص خودکار پلاک خودرو (ALPR) مبتنی بر روش‌های یادگیری عمیق و OCR پیشرفته آغاز شد. روند انجام پژوهش از جمع‌آوری داده‌ها تا طراحی یک اپلیکیشن عملی، نشان‌دهنده آن است که اهداف کلیدی پروژه تا حد زیادی محقق شده‌اند.

مرور دستاوردهای اصلی:

1. طراحی سامانه ALPR: ساختار کلی سامانه شامل چهار بخش پیش‌پردازش، آشکارسازی پلاک، OCR و مکانیزم سوییچینگ تطبیقی طراحی و پیاده‌سازی شد.
2. جمع‌آوری داده‌های بومی: یکی از نوآوری‌های مهم پروژه، گردآوری تصاویر واقعی از منابع داخلی (وبسایت‌ها و تصاویر خیابانی) بود که موجب شد سامانه نسبت به شرایط خاص ایران بهینه‌سازی شود.
3. آموزش مدل‌ها: سه معماری مدرن آشکارساز شامل YOLOv5، YOLOv8 و Faster R-CNN بر روی داده‌های بومی آموزش داده شدند و نقاط قوت و ضعف هر یک مشخص گردید.
4. طراحی مکانیزم Adaptive Switching: این نوآوری موجب شد سامانه بتواند بسته به شرایط ورودی (نور، وضوح و زاویه دید)، بهترین مدل آشکارساز و OCR را انتخاب کند. این ویژگی باعث افزایش دقت و پایداری سامانه در محیط‌های واقعی شد.

5. پیاده‌سازی وب‌اپلیکیشن: در نهایت، سامانه در قالب یک اپلیکیشن تحت وب مبتنی بر Flask پیاده‌سازی شد که امکان بارگذاری تصویر یا ویدئو و دریافت خروجی نهایی (پلاک شناسایی‌شده) را فراهم می‌آورد. میزان تحقق اهداف پژوهش:

- اهداف اصلی پروژه شامل طراحی سامانه، دستیابی به عملکرد بالاتر، و بهبود دقت در شرایط دشوار، به‌طور کامل محقق شدند.
 - اهداف جزئی‌تر مانند ترکیب داده‌های بومی و جهانی، استفاده از OCR های مختلف و طراحی یک مکانیزم سوییچینگ هوشمند نیز عملی شدند.
 - با وجود این، برخی محدودیت‌ها مانند کمبود داده‌های متنوع و چالش در شناسایی پلاک‌های مخدوش همچنان باقی ماند که در بخش پیشنهادات آتی به آن‌ها پرداخته خواهد شد.
- به‌طور کلی، می‌توان نتیجه گرفت که پروژه حاضر هم از نظر علمی (نوآوری در روش‌ها و مدل‌ها) و هم از نظر عملیاتی (قابلیت اجرا در شرایط واقعی ایران) موفق بوده است و زمینه‌ای مناسب برای توسعه‌های بیشتر فراهم ساخته است.

۷-۳- دستاوردهای علمی و عملی پروژه

پروژه حاضر علاوه بر نتایج کاربردی در حوزه تشخیص پلاک خودرو، دارای دستاوردهای علمی و پژوهشی قابل توجهی نیز بوده است. این دستاوردها را می‌توان در دو دسته کلی علمی و عملی تقسیم‌بندی کرد:

۷-۳-۱- دستاوردهای علمی

1. مکانیزم Adaptive

یکی از نوآوری‌های اصلی این پروژه طراحی مازول سوییچینگ تطبیقی بود که قادر است بسته به کیفیت تصویر ورودی، بهترین مدل آشکارساز و OCR را انتخاب کند. این رویکرد در مقایسه با استفاده از یک مدل ثابت، موجب افزایش پایداری و دقت سیستم شد و می‌تواند به‌عنوان الگویی برای سایر کاربردهای بینایی ماشین نیز مطرح شود.

2. ترکیب:

پروژه حاضر نشان داد که ترکیب یک موتور OCR کلاسیک مانند Tesseract با یک معماری یادگیری عمیق مانند CRNN می‌تواند سامانه‌ای انعطاف‌پذیر و مقاوم در برابر شرایط متنوع ایجاد کند. این ترکیب از مزایای سرعت بالای Tesseract در شرایط ساده و دقت بالای CRNN در شرایط سخت بهره می‌برد.

3. بومی:

بخش عمده‌ای از داده‌های آموزشی و آزمایشی این پروژه از تصاویر واقعی پلاک‌های ایرانی جمع‌آوری

شد. این امر موجب شد مدل‌ها به‌طور خاص برای شرایط بومی کشور بهینه‌سازی شوند؛ امری که در بسیاری از پروژه‌های داخلی و خارجی مغفول مانده بود.

۷-۳-۲- دستاوردهای عملی

1. اجرای (Real-Time)

با استفاده از مدل YOLOv5 و نسخه‌های سبک YOLOv8، سامانه توانست در شرایط واقعی با سرعت بالا پلاک‌ها را شناسایی کند. این ویژگی برای کاربردهای عملی مانند مدیریت ترافیک، پارکینگ‌های هوشمند و کنترل عبور و مرور بسیار ارزشمند است.

2. طراحی اپلیکیشن:

پایاده‌سازی یک وب‌اپلیکیشن سبک با استفاده از Flask امکان تعامل ساده کاربران با سامانه را فراهم کرد. این رابط کاربری به کاربران اجازه می‌دهد تصاویر یا ویدئوها را بارگذاری کرده و خروجی نهایی (پلاک شناسایی‌شده) را مشاهده کنند.

3. قابلیت (EdgeDevices)

یکی از دستاوردهای مهم عملی پروژه، بررسی امکان استقرار سامانه روی سخت‌افزارهای لبه مانند Jetson Nano بود. این ویژگی امکان استفاده از سامانه را در محیط‌هایی فراهم می‌سازد که دسترسی به سرورهای قدرتمند یا GPUهای پیشرفته وجود ندارد.

۷-۴- پیشنهادات برای پژوهش‌های آتی

با وجود دستاوردهای ارزشمند، همچنان زمینه‌های متعددی برای بهبود و توسعه سامانه وجود دارد. پیشنهادات زیر می‌تواند مسیر تحقیقات آینده در این حوزه را روشن سازد:

1. برای افزایش دقت و پایداری سامانه، لازم است مجموعه داده‌های گسترده‌تری شامل پلاک‌های انواع خودرو (سواری، سنگین، نظامی، مناطق آزاد) و شرایط آب‌وهوایی متنوع (باران، برف، مه) جمع‌آوری و به مدل‌ها افزوده شود.

2. مدل‌های مبتنی بر ترانسفورمر مانند Vision Transformers (ViT) و Swin Transformers در سال‌های اخیر عملکرد چشمگیری در بینایی ماشین داشته‌اند. به‌کارگیری این مدل‌ها در آشکارسازی و OCR می‌تواند دقت سامانه را بیش از پیش افزایش دهد.

3. اگرچه سامانه در حال حاضر روی سخت‌افزارهای لبه قابل اجراست، اما نیاز به بهینه‌سازی بیشتر وجود دارد. استفاده از تکنیک‌هایی مانند Model Quantization، Pruning و Knowledge Distillation می‌تواند سرعت اجرا را افزایش و مصرف حافظه را کاهش دهد.

4. یکی از مسیرهای مهم آینده، طراحی یک سامانه End-to-End است که از تصویر خام خودرو تا خروجی متن پلاک را در یک مدل واحد پردازش کند. این امر می‌تواند وابستگی به ماژول‌های مجزا (پیش‌پردازش، آشکارساز، OCR) را کاهش دهد و سرعت سیستم را بیشتر کند.
5. در شرایطی که پلاک‌ها مخدوش یا پوشانده شده‌اند، می‌توان از داده‌های مکمل مانند اطلاعات مکانی-زمانی، مدل سه‌بعدی خودرو یا داده‌های صوتی/ویدیویی دیگر استفاده کرد. ترکیب این داده‌ها (Multi-modal Learning) می‌تواند پایداری سامانه را در شرایط دشوار افزایش دهد.

۷-۵- جمع‌بندی فصل و پایان پروژه

پایان‌نامه حاضر با هدف طراحی و پیاده‌سازی یک سامانه تشخیص خودکار پلاک خودرو (ALPR) متناسب با شرایط بومی ایران شکل گرفت. در طول مسیر پژوهش، تلاش شد تا ضمن بهره‌گیری از جدیدترین دستاوردهای حوزه یادگیری عمیق و پردازش تصویر، محدودیت‌های سامانه‌های موجود شناسایی و راهکارهایی نوآورانه برای رفع آن‌ها ارائه شود.

نتیجه‌گیری کلی از پژوهش

بر اساس تحلیل‌ها و آزمایش‌های انجام‌شده در فصل‌های پیشین، می‌توان چنین جمع‌بندی کرد:

1. تحقق اهداف کلان پژوهش: اهداف اصلی از جمله طراحی سامانه، اجرای بلادرنگ، بهبود دقت در شرایط نوری و زاویه‌ای دشوار و پیاده‌سازی رابط کاربری عملیاتی به‌طور کامل محقق شدند.
2. پیش‌پردازش مؤثر: به‌کارگیری تکنیک‌های حذف نویز، اصلاح روشنایی و آستانه‌گذاری تطبیقی نقش مهمی در افزایش کیفیت داده‌ها و ارتقای عملکرد مدل‌ها داشت.
3. مقایسه مدل‌های آشکارساز YOLOv5: سریع‌ترین عملکرد را برای شرایط بلادرنگ ارائه کرد، YOLOv8 بهترین تعادل میان دقت و سرعت داشت، و Faster R-CNN دقیق‌ترین خروجی را در شرایط سخت فراهم نمود.
4. OCR ترکیبی: ترکیب Tesseract و CRNN ثابت کرد که می‌توان از سرعت بالای Tesseract در شرایط ساده و دقت بالای CRNN در شرایط دشوار بهره گرفت.
5. نوآوری: Adaptive Model Switching این مکانیزم باعث شد سامانه در شرایط نوری، زاویه‌ای و کیفیتی مختلف پایداری بیشتری داشته باشد و میانگین دقت کلی سیستم در سناریوهای واقعی افزایش یابد.
6. رابط کاربری کاربردی: پیاده‌سازی اپلیکیشن تحت وب مبتنی بر Flask، امکان آزمایش عملی سامانه توسط کاربران را فراهم کرد و نشان داد که این سیستم قابلیت استقرار در محیط‌های عملی را دارد.

7-6-تأکید بر کاربردپذیری سامانه در شرایط واقعی ایران

ویژگی متمایز پروژه حاضر توجه ویژه به پلاک‌های بومی ایران بود. برخلاف بسیاری از پروژه‌های مشابه که صرفاً بر دیتاست‌های خارجی تکیه کرده‌اند، در این تحقیق داده‌های واقعی از خودروهای داخلی جمع‌آوری و بر روی آن‌ها آموزش انجام شد. این امر موجب شد سامانه در شناسایی پلاک‌های فارسی با فونت‌ها، رنگ‌ها و قالب‌های خاص، دقت بالاتری داشته باشد.

آزمایش‌های عملی روی تصاویر جمع‌آوری‌شده از خیابان‌ها و وبسایت‌های داخلی نشان داد که سامانه در شرایط نوری روز و شب، زوایای مختلف دوربین و حتی کیفیت نسبتاً پایین تصاویر نیز عملکردی قابل قبول دارد. این ویژگی سامانه را به گزینه‌ای عملی برای به‌کارگیری در سیستم‌های واقعی کشور نظیر مدیریت ترافیک شهری، کنترل محدوده طرح ترافیک، مدیریت پارکینگ‌های هوشمند، مرزبانی و پایش امنیتی تبدیل می‌کند.

7-7-چشم‌انداز آینده و ارزش پژوهش

این پژوهش علاوه بر ارائه راهکار علمی، زمینه‌ای برای توسعه‌های صنعتی و تجاری نیز فراهم ساخته است. طراحی سامانه‌ای بومی و هوشمند برای تشخیص پلاک می‌تواند گامی مهم در خودکفایی فناوری‌های هوش مصنوعی در کشور باشد. از سوی دیگر، خروجی‌های این پژوهش می‌توانند به‌عنوان مرجع علمی در انتشار مقالات پژوهشی در حوزه‌های بینایی ماشین و سامانه‌های هوشمند حمل‌ونقل مورد استفاده قرار گیرند.

از منظر صنعتی نیز سامانه حاضر قابلیت ارتقا و تجاری‌سازی دارد. با اندکی بهینه‌سازی و گسترش مجموعه داده‌ها، می‌توان آن را در پروژه‌های واقعی مانند سامانه‌های شهری هوشمند، کنترل خودکار تردد در آزادراه‌ها، مدیریت پارکینگ‌های بزرگ و حتی سامانه‌های نظارت امنیتی به‌کار گرفت.

7-8-جمع‌بندی نهایی

در نهایت می‌توان گفت پروژه حاضر نه تنها یک دستاورد پژوهشی موفق محسوب می‌شود، بلکه بستر محکمی برای تحقیقات آینده و توسعه سامانه‌های عملیاتی در کشور فراهم کرده است. این پایان‌نامه نشان داد که با تلفیق دانش نظری، داده‌های بومی و نوآوری در طراحی معماری، می‌توان سامانه‌ای کارآمد و پایدار برای شرایط واقعی ایران ایجاد کرد. بنابراین، پژوهش حاضر را می‌توان به‌عنوان گامی مهم در جهت توسعه فناوری‌های هوشمند در حوزه حمل‌ونقل و امنیت کشور قلمداد کرد.

1. "Tesseract OCR: Open-source Optical Character Recognition Engine". Retrieved from <https://github.com/tesseract-ocr/tesseract>
2. Jihwan, A., & Lee, S. (2020). "EasyOCR: Open-source Optical Character Recognition". arXiv:2003.10634. Retrieved from <https://arxiv.org/abs/2003.10634>
3. LeCun, Y., Bengio, Y., & Hinton, G. (2015). "Deep Learning". Nature, 521(7553), 436-444. <https://doi.org/10.1038/nature14539>
4. Pizer, S. M., & Zimmerman, J. D. (2005). "Contrast Limited Adaptive Histogram Equalization (CLAHE)". IEEE Transactions on Image Processing, 13(7), 899-906. <https://doi.org/10.1109/TIP.2005.850472>
5. Shorten, C., & Khoshgoftaar, T. M. (2019). "A Survey on Image Data Augmentation for Deep Learning". Journal of Big Data, 6(1), 60. <https://doi.org/10.1186/s40537-019-0197-0>
6. Shi, Y., & Yang, L. (2020). "Edge Computing for Real-time Data Processing and Applications". IEEE Access, 8, 88704-88717. <https://doi.org/10.1109/ACCESS.2020.2994006>
7. Levenshtein, V. I. (1966). "Binary Codes Capable of Correcting Deletions, Insertions, and Reversals". Soviet Physics Doklady, 10(8), 707-710. [Link to Article](#)